Análisis de la Depresión Estudiantil

Student Depression Dataset

Angelo Alejandro Ibañez Hernandez 20212020007 Alejandro Gomez Moyano 20222020073 Juan David C

14/04/2026

Contents

PARTE 1 - DATASET **2**
1. Descripción del conjunto de datos . . . 2

PARTE 2 - ANÁLISIS UNIVARIADO **2**
Clasificación general de variables . . . 3

VARIABLES CUANTITATIVAS **3**
Edad (Age) . . . 3
Presión Académica (Academic Pressure) . . . 5
Presión Laboral (Work Pressure) . . . 7
CGPA (Rendimiento académico) . . . 9
Estrés financiero . . . 11
Horas de estudio/trabajo (Work/Study Hours) . . . 13
Género (Gender) . . . 15
Ciudad (City) . . . 16
Profesión (Profession) . . . 17
Duración del sueño (Sleep Duration) . . . 18
Hábitos alimenticios (Dietary Habits) . . . 19
Pensamientos suicidas . . . 20
Historial familiar . . . 21
Variable objetivo: Depresión . . . 22

PARTE 3 - LIMPIEZA DE DATOS **23**
1. Visualización dataset base . . . 23
2. Eliminacion de duplicados . . . 26
3. Correccion de tipos de datos . . . 26
4. Eliminacion de la variable ID . . . 27

PARTE 4 - ANÁLISIS BIVARIADO **27**
4.1 Preparación de datos para análisis bivariado . . . 27
4.2 Estrés financiero vs Depresión . . . 28
4.3 Horas de estudio/trabajo vs Depresión . . . 29
4.4 Hábitos alimenticios vs Depresión . . . 30
4.5 Presión académica vs Depresión . . . 31
4.6 Duración del sueño vs Depresión . . . 32

PARTE 5. Primeros hallazgos **33**
¿Qué patrones encontraron? . . . 33
¿Qué variables dominan el comportamiento? . . . 34

¿Qué conclusiones pueden obtener? . . . 34
¿Qué tipo de problema podría resolverse con estos datos? . . . 34

PARTE 6. Análisis Multivariado Básico **34**
Matriz de Correlación . . . 34
¿Qué patrones globales se observan? . . . 36
Coordenadas Paralelas . . . 36

PARTE 7. Medidas descriptivas multivariantes **38**
Media Vectorial . . . 38
Dispersión . . . 39
Dependencia . . . 40

PARTE 8. Interpretación global **41**

PARTE 1 - DATASET

1. Descripción del conjunto de datos

El dataset utilizado corresponde a un conjunto de datos sobre depresión en estudiantes, el cual contiene información relacionada con factores académicos, personales y de salud mental.

Este dataset cuenta con aproximadamente 27,901 registros y 18 variables, incluyendo tanto variables cualitativas como cuantitativas.

Tipo de problema

El conjunto de datos es adecuado para un problema de clasificación, ya que contiene una variable objetivo denominada `Depression`, la cual indica si un estudiante presenta depresión (1) o no (0).

Justificación del dataset

Este dataset es pertinente para un análisis estadístico multidimensional debido a que:

- Contiene múltiples variables que describen diferentes dimensiones del individuo (académica, personal, económica y psicológica).
- Permite analizar relaciones entre variables que potencialmente influyen en la depresión.
- Presenta una combinación de variables numéricas y categóricas, lo cual es ideal para análisis univariado, bivariado y multivariado.

Carga del Dataset

```r
data <- read.csv("Student Depression Dataset.csv", stringsAsFactors = FALSE)
```

PARTE 2 - ANÁLISIS UNIVARIADO

En esta sección se analizan todas las variables del dataset de manera individual. Se clasifican según su tipo y se justifica su relevancia dentro del análisis de depresión estudiantil.

Clasificación general de variables

Variables cuantitativas

- Age
- Academic Pressure
- Work Pressure
- CGPA
- Study Satisfaction
- Job Satisfaction
- Work/Study Hours
- Financial Stress

Variables cualitativas

- Gender
- City
- Profession
- Degree
- Sleep Duration
- Dietary Habits
- Suicidal Thoughts
- Family History of Mental Illness
- Depression

VARIABLES CUANTITATIVAS

Edad (Age)

Tipo de variable

Cuantitativa discreta

Justificación

La edad es fundamental en estudios de salud mental, ya que diferentes etapas de la vida presentan distintos niveles de vulnerabilidad psicológica.

Gráficos

```r
hist(data$Age, col = "steelblue", xlab = "Edad" , main = "Distribución de la Edad")
```

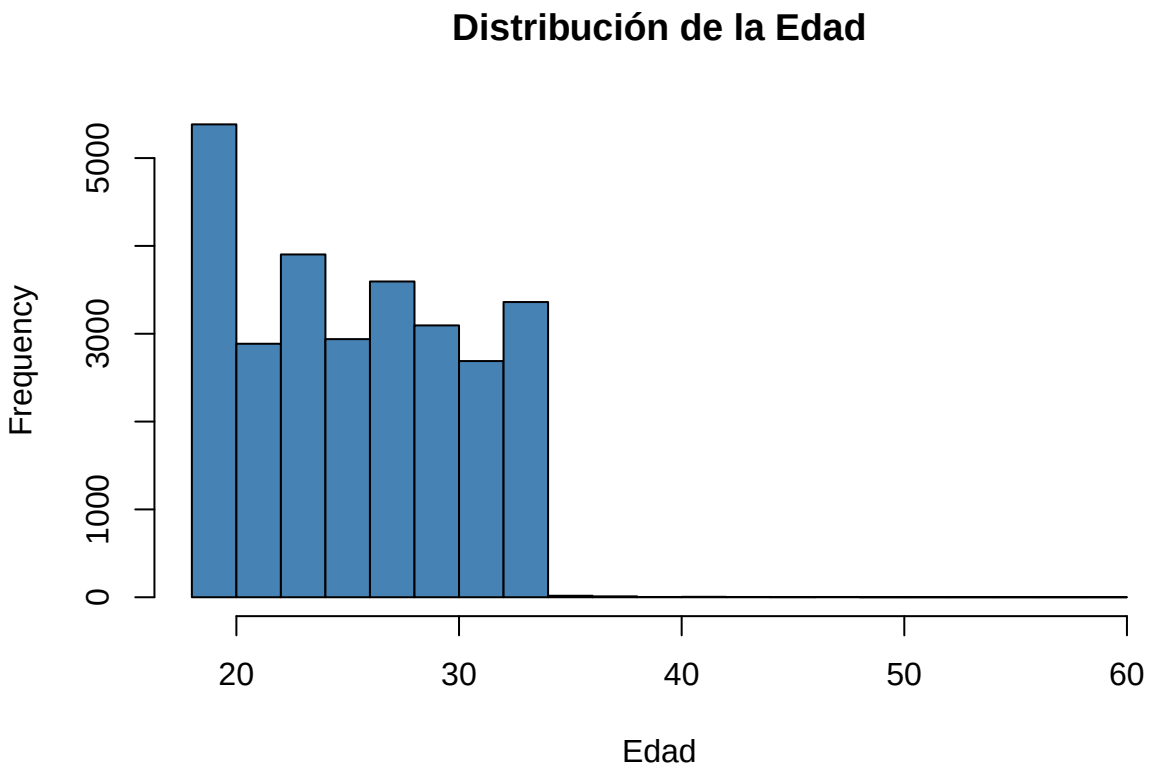


```r
boxplot(data$Age, col = "steelblue",ylab = "Edad" , main = "Boxplot de la Edad")
```

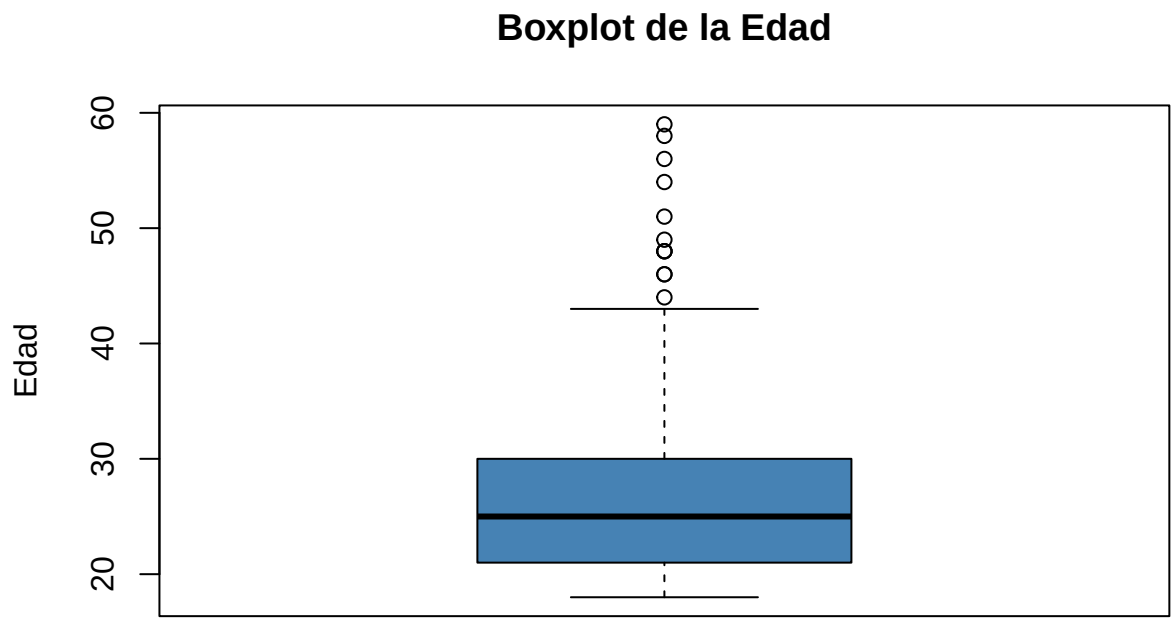


```r
mean(data$Age, na.rm = TRUE)
```

```
## [1] 25.8223
```

```r
median(data$Age, na.rm = TRUE)
```

```
## [1] 25
```

```r
sd(data$Age, na.rm = TRUE)
```

```
## [1] 4.905687
```

La distribución muestra una alta concentración entre los 18 y 27 años, lo cual confirma que la muestra representa principalmente estudiantes universitarios tradicionales. Sin embargo, la presencia de un segundo grupo entre los 28 y 35 años evidencia una población no homogénea, posiblemente compuesta por estudiantes de posgrado o educación continua.

El boxplot evidencia valores atípicos en edades superiores a 45 años, lo que sugiere casos aislados. Estos no deben eliminarse automáticamente, pero sí considerarse en análisis posteriores, ya que pueden introducir sesgos si no se controlan.

La edad no solo describe la población, sino que podria sugerir que la depresión deberia analizarse considerando diferencias generacionales, ya que las causas pueden variar entre estudiantes jóvenes y adultos.

Presión Académica (Academic Pressure)

Tipo de variable

Cuantitativa ordinal

Justificación

Es una de las variables más relevantes, ya que la carga académica es un factor directamente asociado con el estrés y la depresión en estudiantes.

Gráficos

```
hist(data$Academic.Pressure, col = "steelblue", xlab = "Presión Académica" , main = "Distribución de la
```

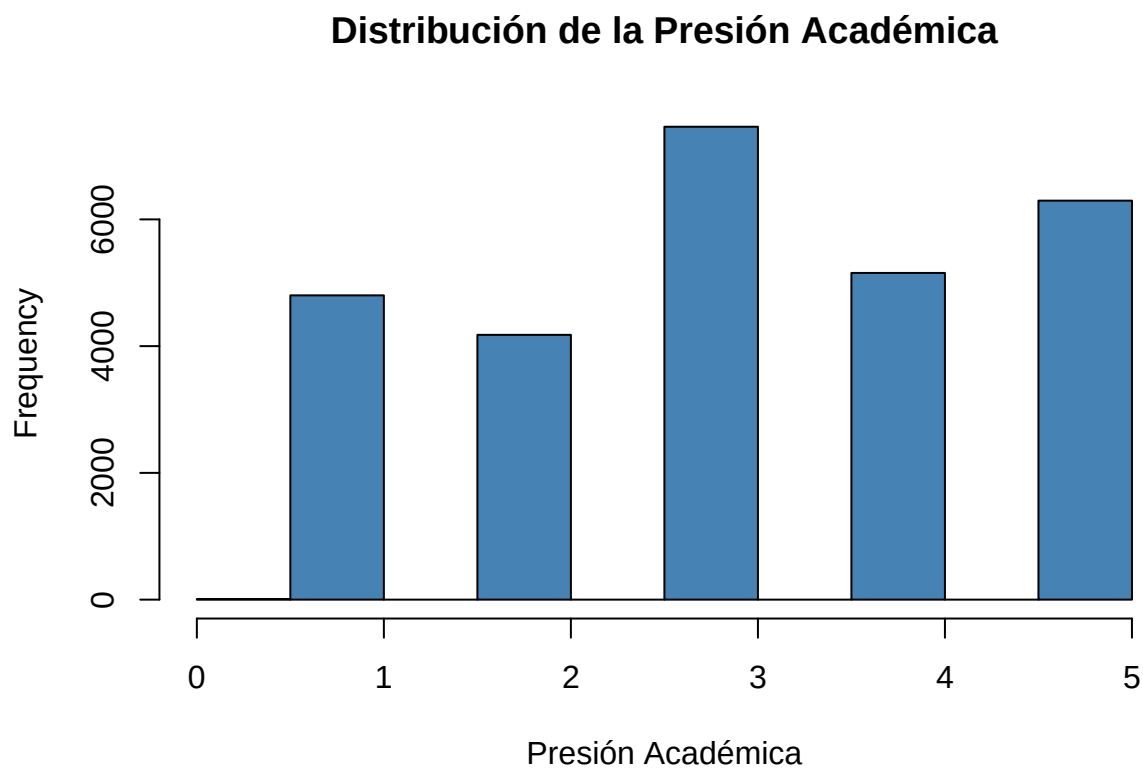


```
boxplot(data$Academic.Pressure, col = "steelblue",ylab = "Presión Académica" , main = "Boxplot de la Pre
```

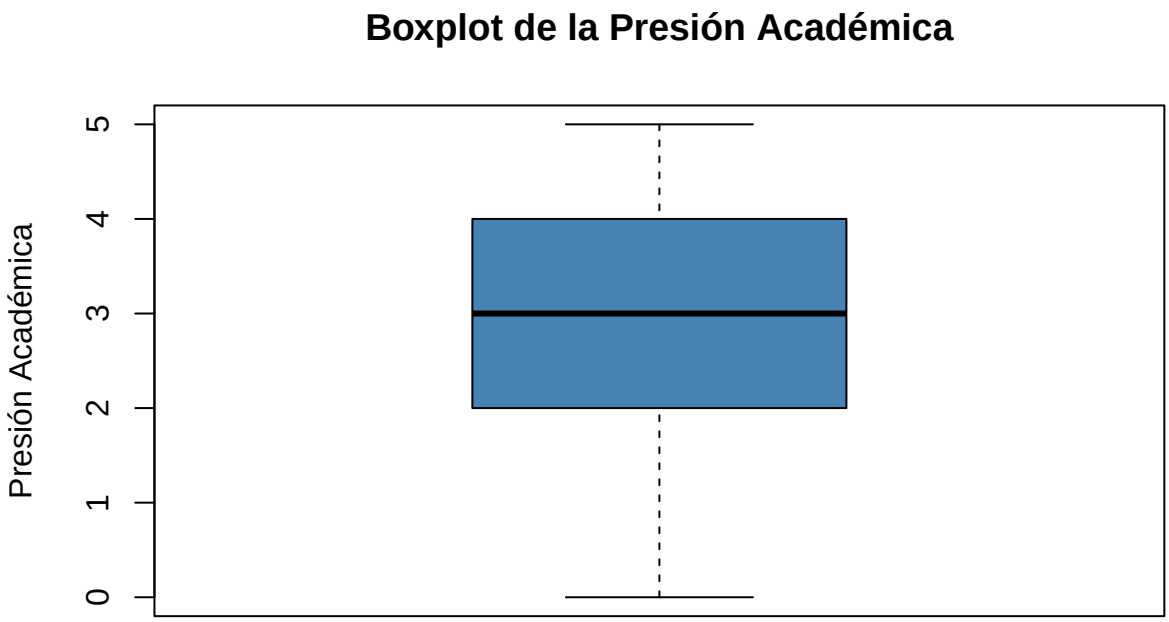


```r
mean(data$Academic.Pressure, na.rm = TRUE)
```

```
## [1] 3.141214
```

```r
median(data$Academic.Pressure, na.rm = TRUE)
```

```
## [1] 3
```

```r
sd(data$Academic.Pressure, na.rm = TRUE)
```

```
## [1] 1.381465
```

La distribución se concentra en valores medios-altos (3 a 5), lo que indica que la presión académica es una condición generalizada en la muestra.

La baja dispersión relativa sugiere que la presión no es un fenómeno aislado, sino estructural dentro del entorno estudiantil.

Más que un factor diferenciador, la presión académica parece ser una condición base del sistema educativo, por lo que su impacto en la depresión debe analizarse en combinación con otras variables (no de forma aislada).

Presión Laboral (Work Pressure)

Justificación

Permite analizar el impacto del trabajo en estudiantes que estudian y trabajan simultáneamente.

Gráficos

```
hist(data$Work.Pressure, col = "steelblue", xlab = "Presión Laboral" , main = "Distribución de la Presi
```

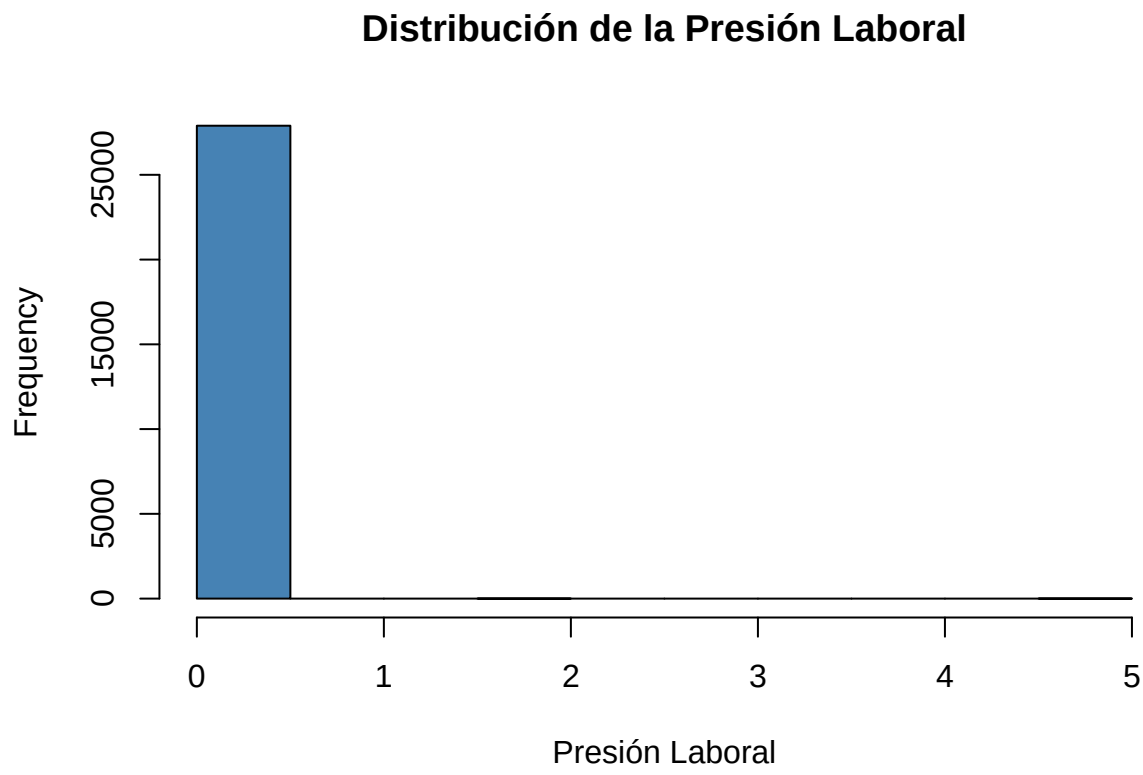


```
boxplot(data$Work.Pressure, col = "steelblue",ylab = "Presión Laboral" , main = "Boxplot de la Presión
```

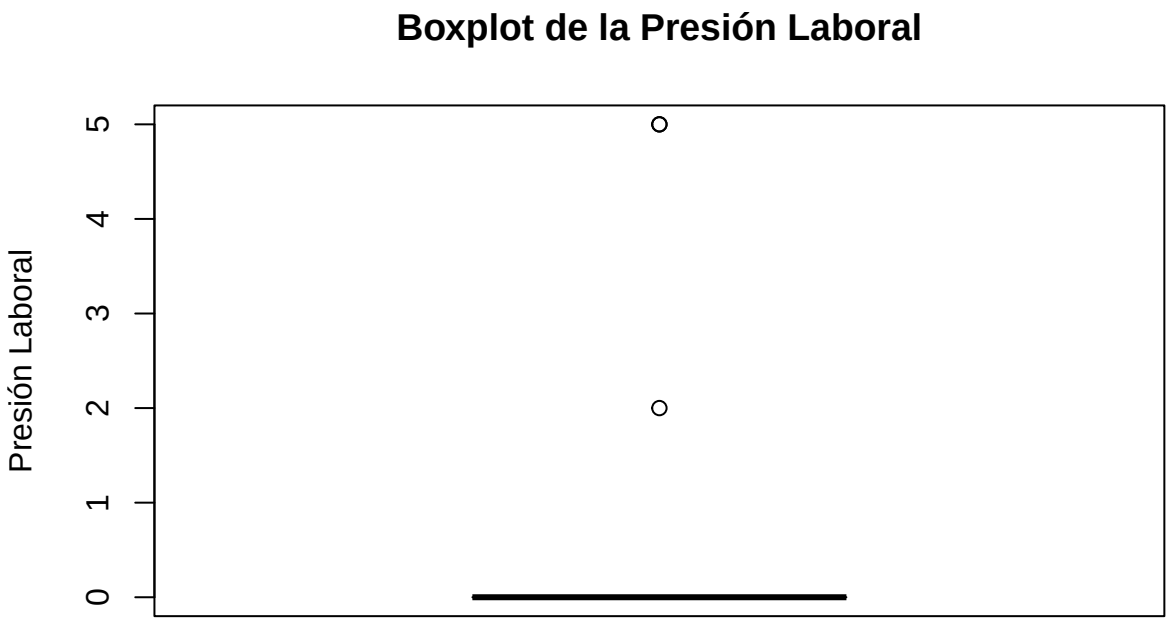


```r
mean(data$Work.Pressure, na.rm = TRUE)
```

```
## [1] 0.0004300921
```

```r
median(data$Work.Pressure, na.rm = TRUE)
```

```
## [1] 0
```

```r
sd(data$Work.Pressure, na.rm = TRUE)
```

```
## [1] 0.04399203
```

La distribución está completamente sesgada hacia el valor 0, lo que indica ausencia casi total de presión laboral.

Esta variable no tiene capacidad explicativa en este dataset y debería:

- eliminarse del modelo, o
- utilizarse únicamente para confirmar que la población es mayoritariamente no trabajadora.

CGPA (Rendimiento académico)

Tipo de variable

Cuantitativa continua

Justificación

El rendimiento académico puede influir directamente en el bienestar emocional.

Gráficos

```
hist(data$CGPA, col = "steelblue", xlab = "CGPA" , main = "Distribución del Rendimiento académico")
```

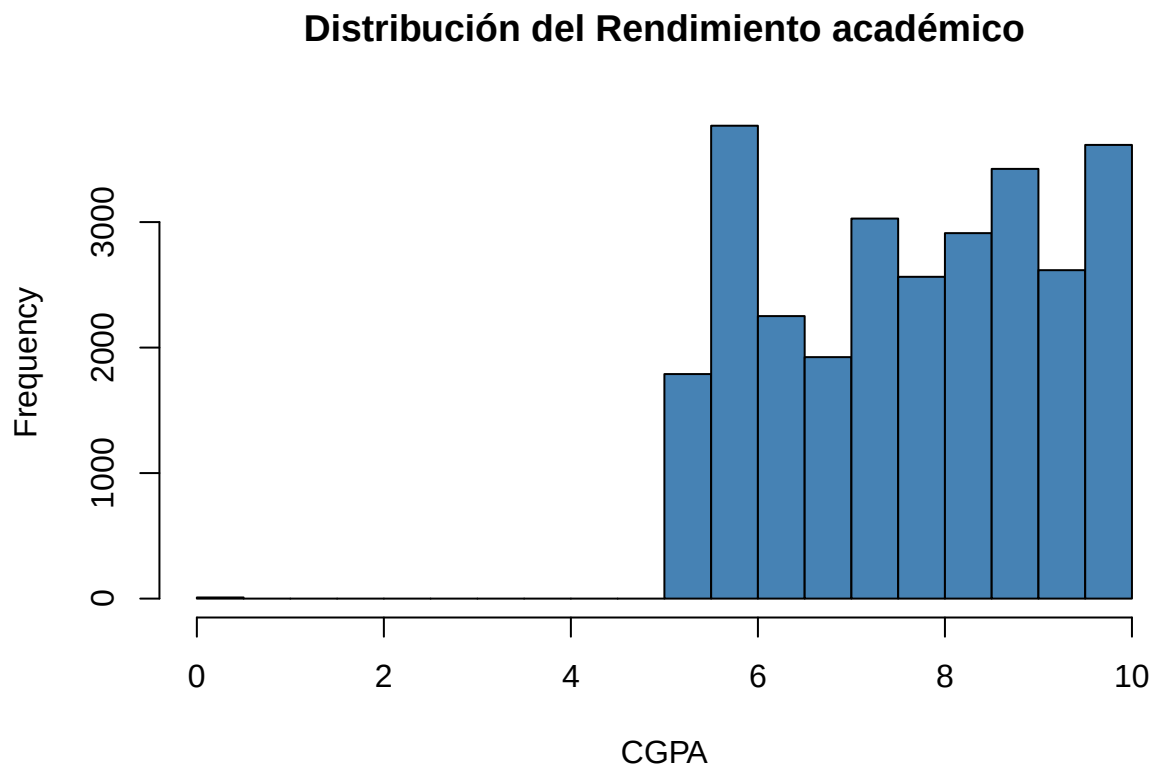


```
boxplot(data$CGPA, col = "steelblue",ylab = "CGPA" , main = "Boxplot de la Rendimiento académico")
```

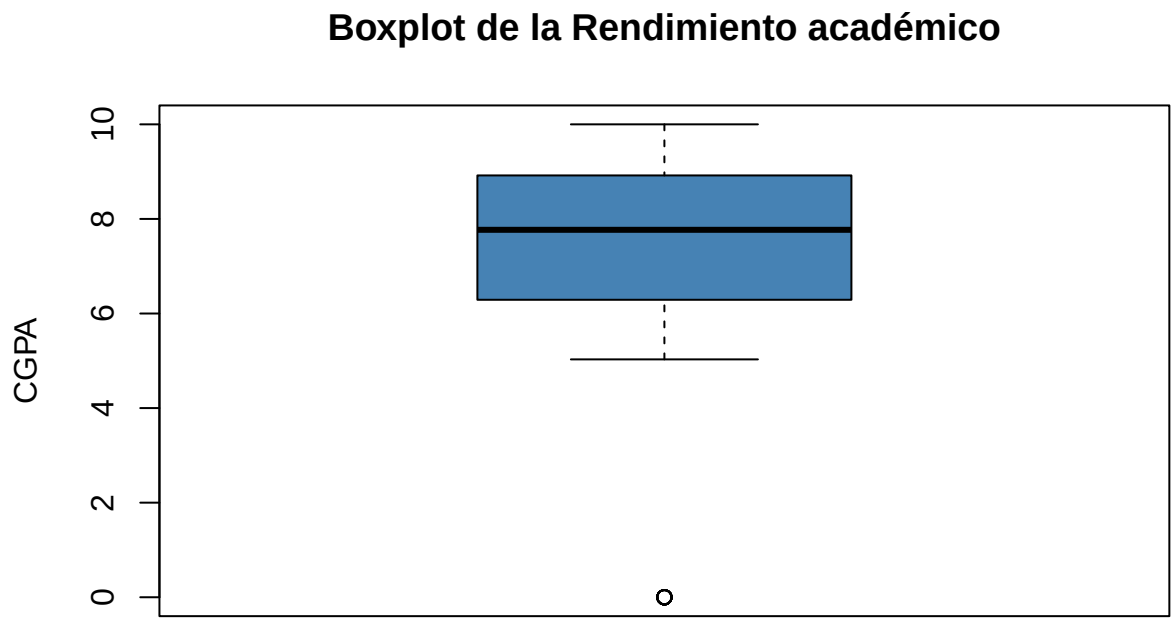


```r
mean(data$CGPA, na.rm = TRUE)
```

```
## [1] 7.656104
```

```r
median(data$CGPA, na.rm = TRUE)
```

```
## [1] 7.77
```

```r
sd(data$CGPA, na.rm = TRUE)
```

```
## [1] 1.470707
```

La distribución muestra una clara concentración en valores altos (7 a 10), con baja dispersión.

Esto indica que:

- la mayoría de estudiantes tiene buen rendimiento
- no hay una gran variabilidad académica

El alto rendimiento no actúa como factor protector contra la depresión, Por el contrario, puede estar asociado a:

- autoexigencia
- presión por mantener resultados

Esto sugerir una relación interesante: "alto rendimiento bienestar emocional"

Estrés financiero

Tipo de variable

Cuantitativa ordinal

Justificación

El estrés económico es un factor clave en la salud mental.

Gráficos

```
hist(data$Financial.Stress, col = "steelblue", xlab = "Estrés financiero" , main = "Distribución del Es
```

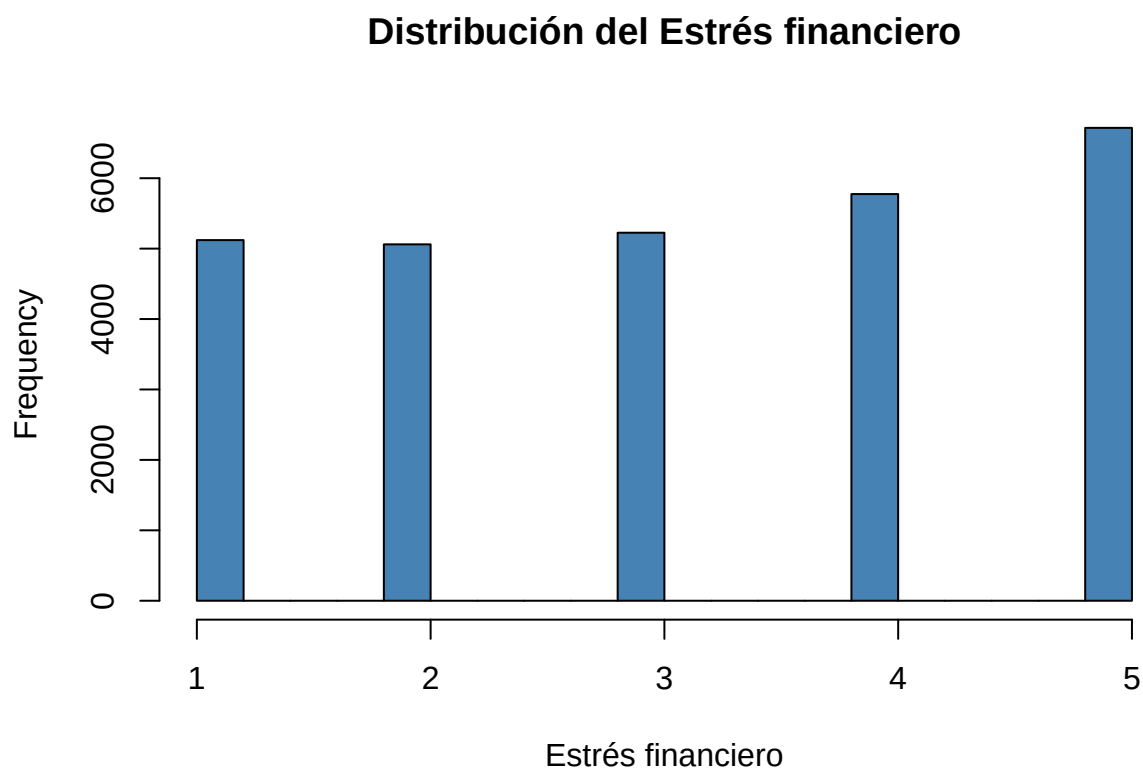


```
boxplot(data$Financial.Stress, col = "steelblue",ylab = "Estrés financiero" , main = "Boxplot de la Est
```

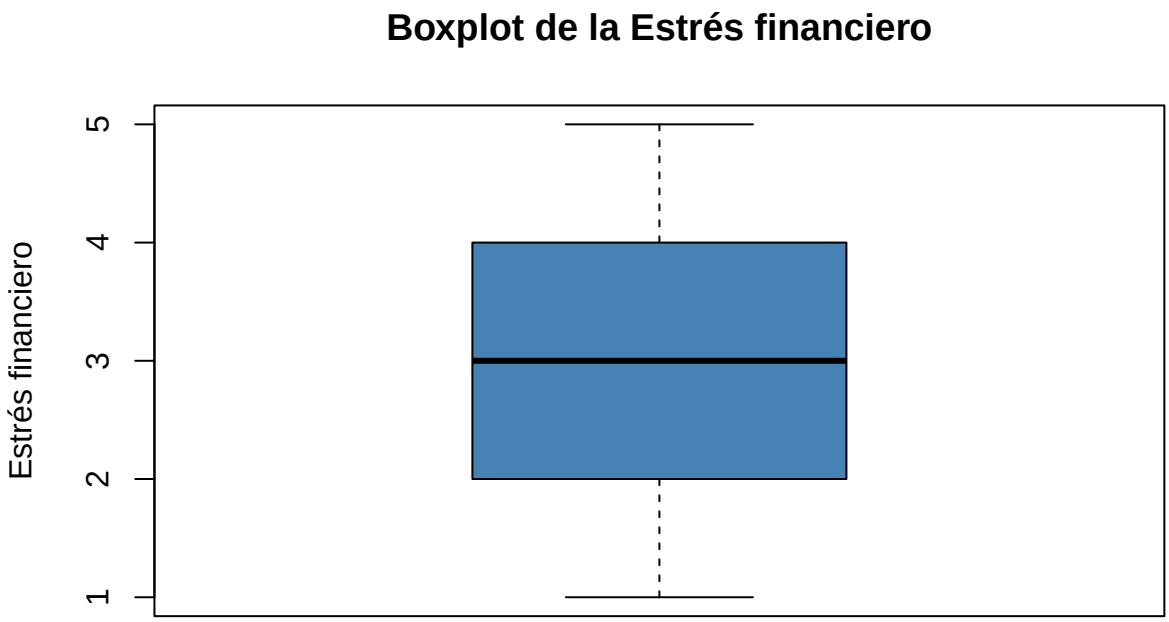


```r
mean(data$Financial.Stress, na.rm = TRUE)
```

```
## [1] 3.139867
```

```r
median(data$Financial.Stress, na.rm = TRUE)
```

```
## [1] 3
```

```r
sd(data$Financial.Stress, na.rm = TRUE)
```

```
## [1] 1.437347
```

Aunque los valores se distribuyen entre 1 y 5, existe una concentración alrededor de 3 y 4, lo que indica niveles moderados a altos de estrés económico.

No es correcto decir que es homogéneo; porque hay suficiente variabilidad.

El estrés financiero sí puede ser un factor discriminante importante, especialmente porque:

- no todos los estudiantes lo experimentan igual
- puede interactuar con otras variables (horas de trabajo, sueño, etc.)

Horas de estudio/trabajo (Work/Study Hours)

Justificación

Relaciona carga diaria con fatiga.

Gráficos

```
hist(data$Work.Study.Hours, col = "steelblue", xlab = "Horas de estudio/trabajo" , main = "Distribución
```

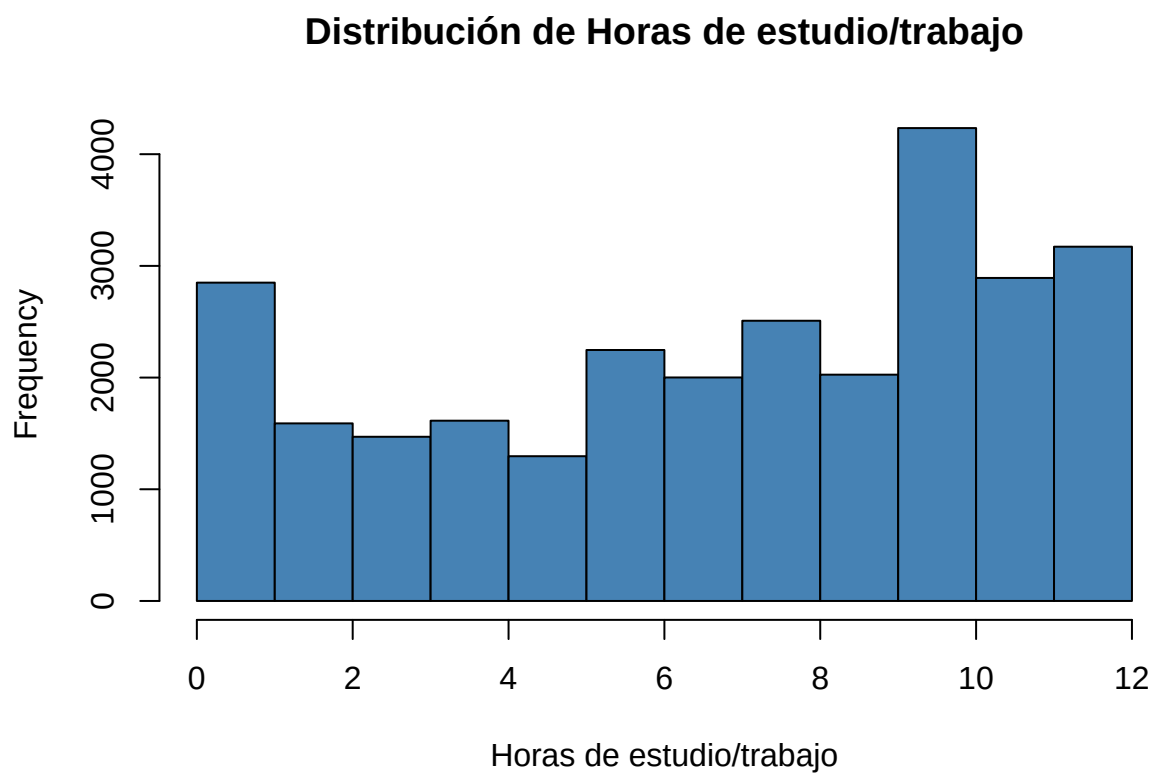


```
boxplot(data$Work.Study.Hours, col = "steelblue",ylab = "Horas de estudio/trabajo" , main = "Boxplot de
```

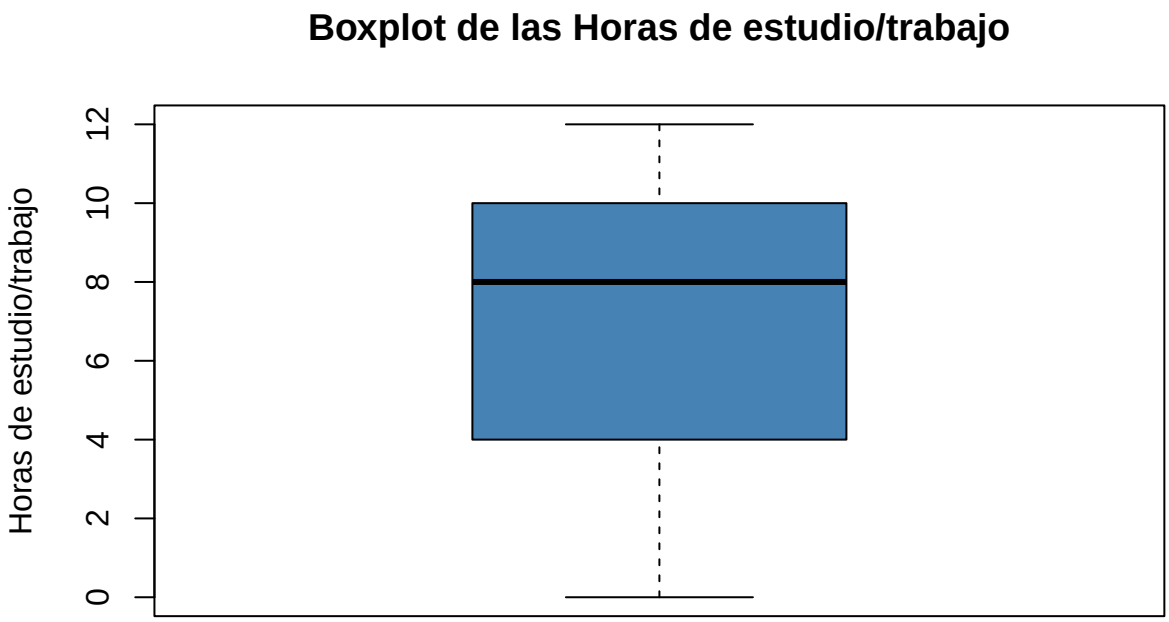


```r
mean(data$Work.Study.Hours, na.rm = TRUE)
```

```
## [1] 7.156984
```

```r
median(data$Work.Study.Hours, na.rm = TRUE)
```

```
## [1] 8
```

```r
sd(data$Work.Study.Hours, na.rm = TRUE)
```

```
## [1] 3.707642
```

La distribución muestra una concentración entre 6 y 10 horas, con algunos valores extremos cercanos a 12.

El boxplot evidencia una asimetría hacia valores altos, indicando que hay estudiantes con cargas significativamente elevadas.

Existe un grupo importante en riesgo de sobrecarga académica, lo que puede derivar en:

- fatiga
- burnout
- alteraciones del sueño

Género (Gender)

Tipo de variable

Cualitativa nominal

Justificación

Permite analizar diferencias de depresión entre hombres y mujeres.

Gráficos

```
barplot(table(data$Gender),
        main = "Distribución por Género",
        col = c("coral", "steelblue"))
```

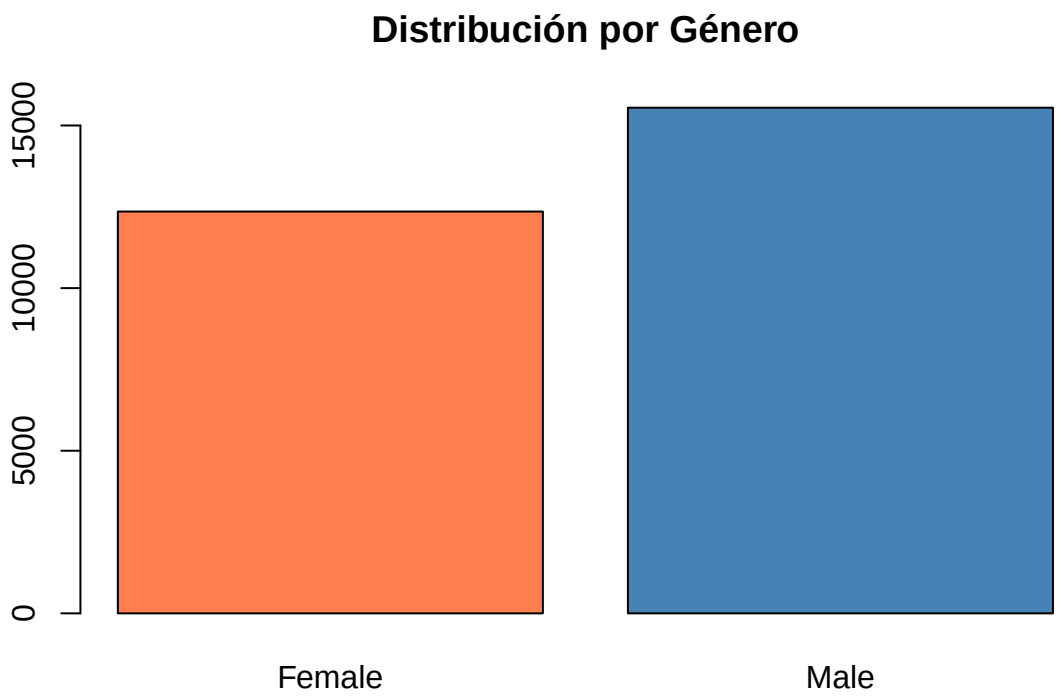

El gráfico muestra una distribución relativamente balanceada (aunque puede haber ligera diferencia).

Por sí sola, esta variable no explica la depresión, pero es fundamental en análisis bivariados para detectar:

- diferencias en prevalencia
- vulnerabilidad diferencial

Ciudad (City)

Justificación

Puede capturar diferencias contextuales.

Gráficos

```
barplot(table(data$City),
        main = "Distribución por Ciudad",
        col = c("coral", "steelblue"))
```

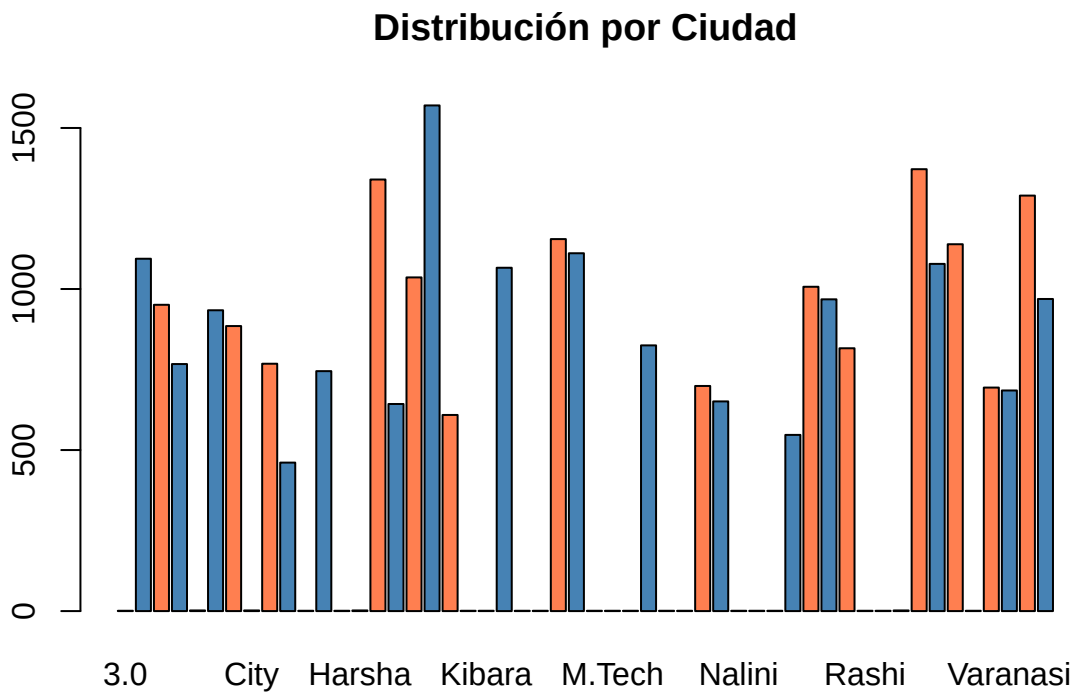


```r
length(unique(data$City))
```

```
## [1] 52
```

La alta cardinalidad (52 ciudades) dificulta su análisis univariado.

No es útil de forma individual, pero tiene alto valor si se:

- agrupa (por región, tamaño de ciudad)
- usa en modelos predictivos

Sin embargo para el caso de este analisis no se tendra en cuenta pues no parece tener una relacion con las causas de la depresion como otras variables

Profesión (Profession)

Gráficos

```r
barplot(table(data$Profession),
        main = "Distribución por Profesion",
        col = c("coral", "steelblue"))
```

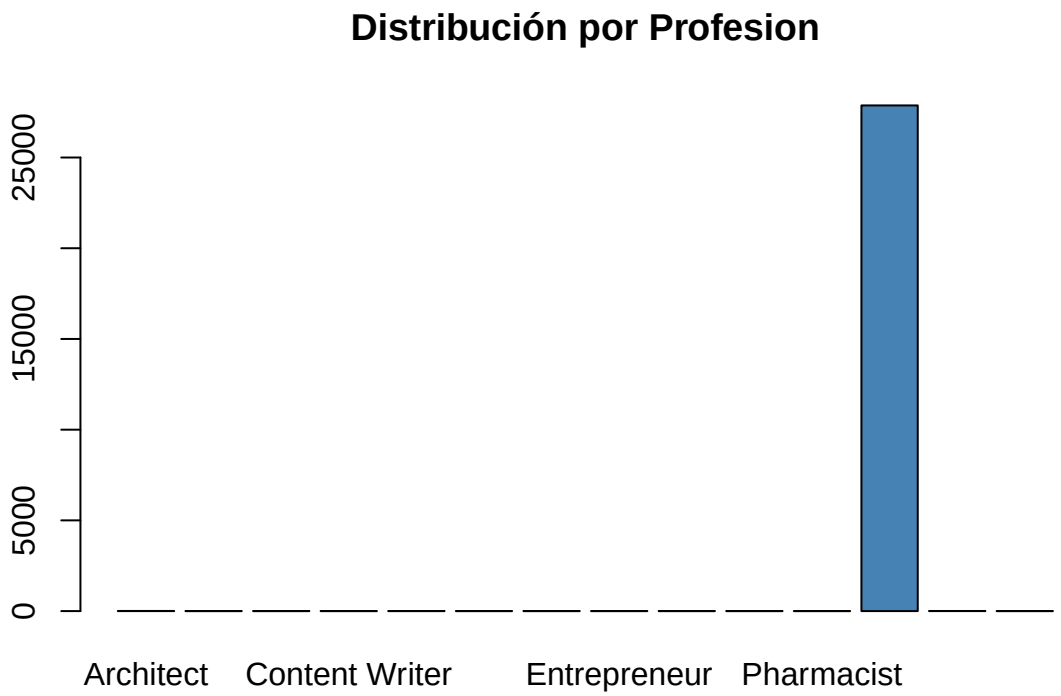


```r
length(unique(data$Profession))
```

```
## [1] 14
```

Similar a ciudad, presenta muchas categorías. Su análisis univariado no es informativo, pero puede ser útil en reducción de dimensionalidad o agrupación.

Duración del sueño (Sleep Duration)

Gráficos

```r
barplot(table(data$Sleep.Duration),
        main = "Distribución por Duración del sueño",
        col = c("coral", "steelblue"))
```

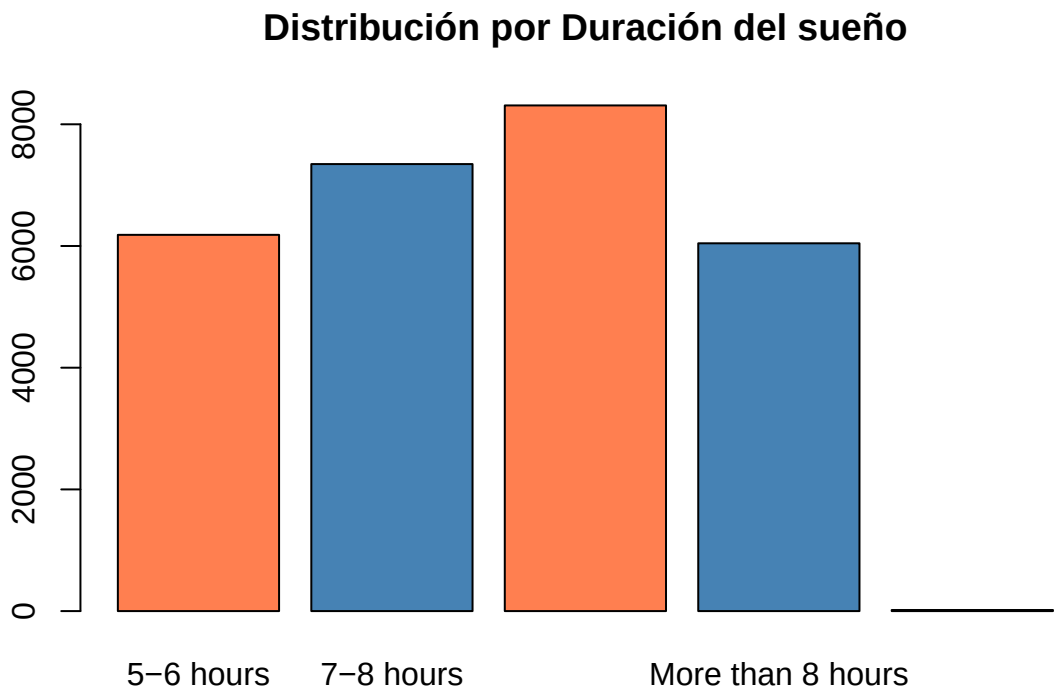

Se observa predominancia menos de 5 horas, lo cual está por debajo del rango recomendado.

Esto evidencia un patrón preocupante: privación de sueño generalizada

Y esto está fuertemente relacionado con:

- ansiedad
- depresión
- bajo bienestar

Hábitos alimenticios (Dietary Habits)

Gráficos

```
barplot(table(data$Dietary.Habits),
        main = "Distribución por Hábitos alimenticios",
        col = c("coral", "steelblue"))
```

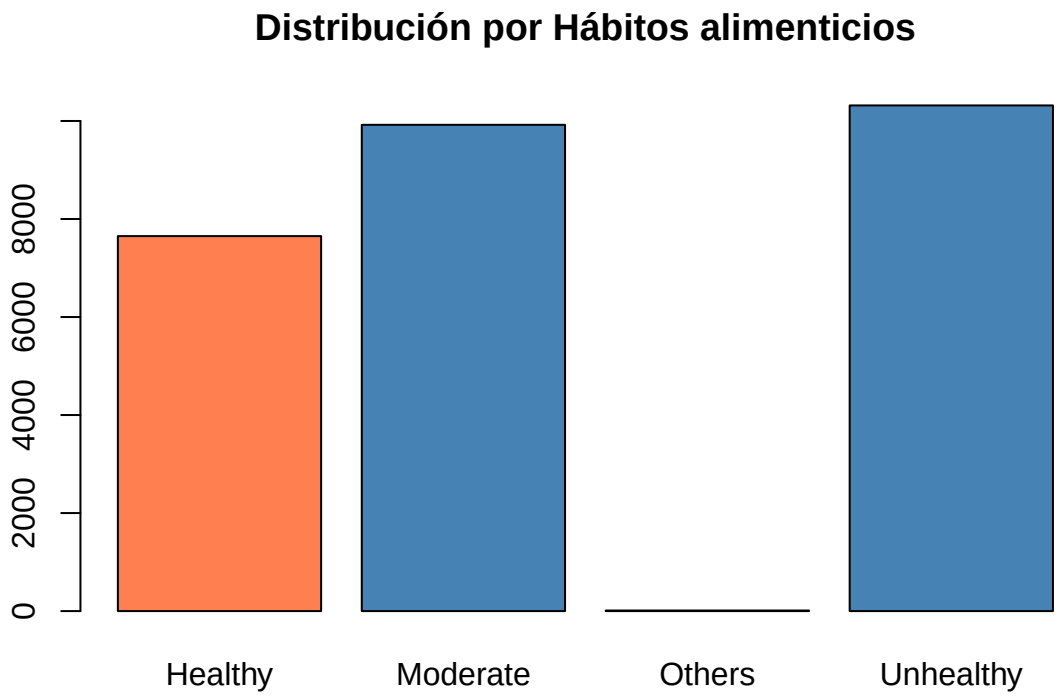

Predominan hábitos moderados, pero existe presencia de categorías no saludables.

Más que un factor directo, parece actúar como indicador de: - estilo de vida desorganizado - posible falta de autocuidado

Pensamientos suicidas

Gráficos

```
barplot(table(data$Have.you.ever.had.suicidal.thoughts),
        main = "Distribución por Pensamientos Suicidas",
        col = c("coral", "steelblue"))
```

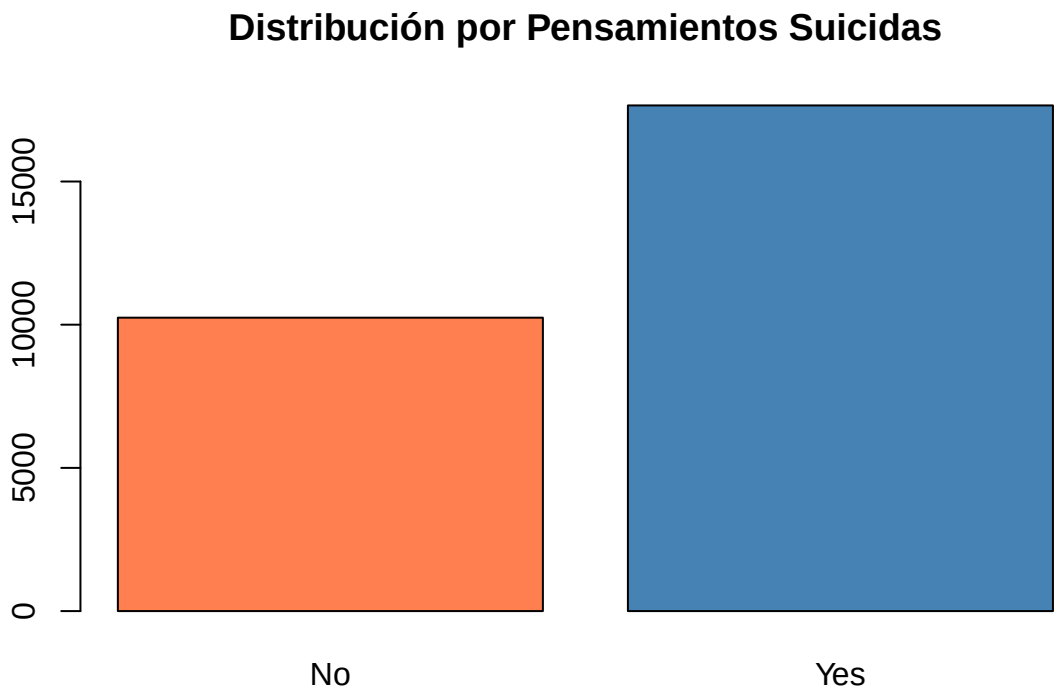

La presencia significativa de respuestas "Yes" indica una población con alto riesgo psicológico.

Esta es probablemente la variable más predictiva de depresión, y además:

- refleja gravedad del problema
- puede usarse como indicador temprano

Historial familiar

Gráficos

```
barplot(table(data$Family.History.of.Mental.Illness),
        main = "Distribución por Historial familiar",
        col = c("coral", "steelblue"))
```

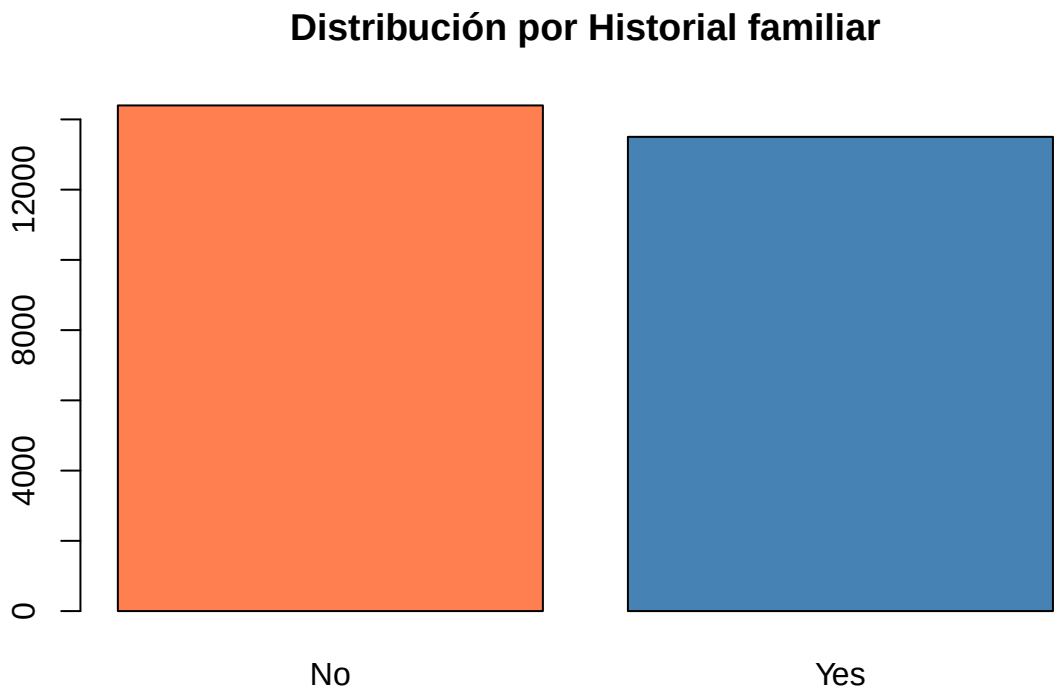

Existe una proporción importante de estudiantes con antecedentes familiares.

Este factor podria sugerir:

- predisposición genética
- influencia del entorno familiar

Variable objetivo: Depresión

Gráficos

```
barplot(table(data$Depression),
        main = "Distribución por Depresión",
        col = c("coral", "steelblue"))
```

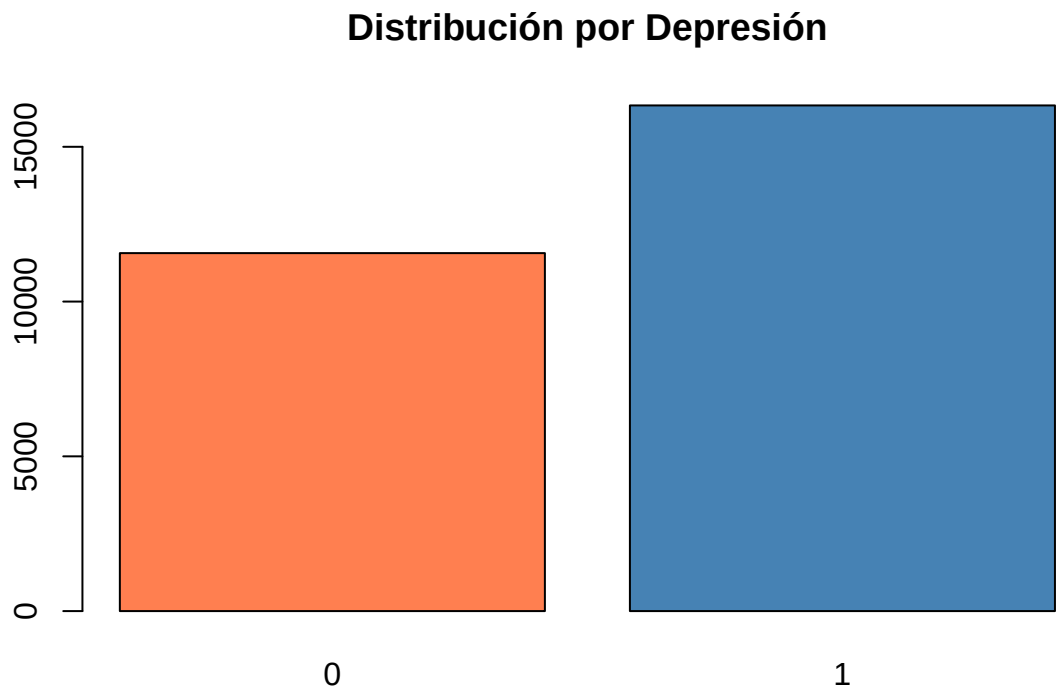

Se observa una proporción de aproximadamente 58.5% con depresión, lo cual indica:

- el dataset está ligeramente desbalanceado hacia la clase positiva
- alta prevalencia del fenómeno
- No es un problema raro → es generalizado
- Se justifica completamente el análisis

PARTE 3 - LIMPIEZA DE DATOS

1. Visualización dataset base

```r
head(data)
```

```
##   id Gender Age          City Profession Academic.Pressure Work.Pressure CGPA
## 1  2   Male  33 Visakhapatnam    Student                 5             0 8.97
## 2  8 Female  24     Bangalore    Student                 2             0 5.90
## 3 26   Male  31      Srinagar    Student                 3             0 7.03
## 4 30 Female  28      Varanasi    Student                 3             0 5.59
## 5 32 Female  25        Jaipur    Student                 4             0 8.13
## 6 33   Male  29          Pune    Student                 2             0 5.70
##   Study.Satisfaction Job.Satisfaction    Sleep.Duration Dietary.Habits  Degree
## 1                  2                0         5-6 hours        Healthy B.Pharm
## 2                  5                0         5-6 hours       Moderate     BSc
## 3                  5                0 Less than 5 hours        Healthy      BA
## 4                  2                0         7-8 hours       Moderate     BCA
```

```
## 5                  3                0         5-6 hours       Moderate  M.Tech
## 6                  3                0 Less than 5 hours        Healthy     PhD
##   Have.you.ever.had.suicidal.thoughts.. Work.Study.Hours Financial.Stress
## 1                                   Yes                3                1
## 2                                    No                3                2
## 3                                    No                9                1
## 4                                   Yes                4                5
## 5                                   Yes                1                1
## 6                                    No                4                1
##   Family.History.of.Mental.Illness Depression
## 1                               No          1
## 2                              Yes          0
## 3                              Yes          0
## 4                              Yes          1
## 5                               No          0
## 6                               No          0
```

```r
str(data)
```

```
## 'data.frame':    27901 obs. of  18 variables:
##  $ id                                  : int  2 8 26 30 32 33 52 56 59 62 ...
##  $ Gender                              : chr  "Male" "Female" "Male" "Female" ...
##  $ Age                                 : num  33 24 31 28 25 29 30 30 28 31 ...
##  $ City                                : chr  "Visakhapatnam" "Bangalore" "Srinagar" "Varanasi" ...
##  $ Profession                          : chr  "Student" "Student" "Student" "Student" ...
##  $ Academic.Pressure                   : num  5 2 3 3 4 2 3 2 3 2 ...
##  $ Work.Pressure                       : num  0 0 0 0 0 0 0 0 0 0 ...
##  $ CGPA                                : num  8.97 5.9 7.03 5.59 8.13 5.7 9.54 8.04 9.79 8.38 ...
##  $ Study.Satisfaction                  : num  2 5 5 2 3 3 4 4 1 3 ...
##  $ Job.Satisfaction                    : num  0 0 0 0 0 0 0 0 0 0 ...
##  $ Sleep.Duration                      : chr  "5-6 hours" "5-6 hours" "Less than 5 hours" "7-8 hours
##  $ Dietary.Habits                      : chr  "Healthy" "Moderate" "Healthy" "Moderate" ...
##  $ Degree                              : chr  "B.Pharm" "BSc" "BA" "BCA" ...
##  $ Have.you.ever.had.suicidal.thoughts..: chr  "Yes" "No" "No" "Yes" ...
##  $ Work.Study.Hours                    : num  3 3 9 4 1 4 1 0 12 2 ...
##  $ Financial.Stress                    : num  1 2 1 5 1 1 2 1 3 5 ...
##  $ Family.History.of.Mental.Illness    : chr  "No" "Yes" "Yes" "Yes" ...
##  $ Depression                          : int  1 0 0 1 0 0 0 0 1 1 ...
```

```r
summary(data)
```

```
##        id            Gender               Age            City
##  Min.   :     2   Length:27901       Min.   :18.00   Length:27901
##  1st Qu.: 35039   Class :character   1st Qu.:21.00   Class :character
##  Median : 70684   Mode  :character   Median :25.00   Mode  :character
##  Mean   : 70442                      Mean   :25.82
##  3rd Qu.:105818                      3rd Qu.:30.00
##  Max.   :140699                      Max.   :59.00
##
##   Profession        Academic.Pressure Work.Pressure            CGPA
##  Length:27901       Min.   :0.000     Min.   :0.0000000   Min.   : 0.000
##  Class :character   1st Qu.:2.000     1st Qu.:0.0000000   1st Qu.: 6.290
##  Mode  :character   Median :3.000     Median :0.0000000   Median : 7.770
##                     Mean   :3.141     Mean   :0.0004301   Mean   : 7.656
##                     3rd Qu.:4.000     3rd Qu.:0.0000000   3rd Qu.: 8.920
```

```
##                     Max.   :5.000     Max.   :5.0000000   Max.   :10.000
##
##  Study.Satisfaction Job.Satisfaction   Sleep.Duration     Dietary.Habits
##  Min.   :0.000      Min.   :0.000000   Length:27901       Length:27901
##  1st Qu.:2.000      1st Qu.:0.000000   Class :character   Class :character
##  Median :3.000      Median :0.000000   Mode  :character   Mode  :character
##  Mean   :2.944      Mean   :0.000681
##  3rd Qu.:4.000      3rd Qu.:0.000000
##  Max.   :5.000      Max.   :4.000000
##
##     Degree          Have.you.ever.had.suicidal.thoughts.. Work.Study.Hours
##  Length:27901       Length:27901                          Min.   : 0.000
##  Class :character   Class :character                      1st Qu.: 4.000
##  Mode  :character   Mode  :character                      Median : 8.000
##                                                           Mean   : 7.157
##                                                           3rd Qu.:10.000
##                                                           Max.   :12.000
##
##  Financial.Stress Family.History.of.Mental.Illness   Depression
##  Min.   :1.00     Length:27901                     Min.   :0.0000
##  1st Qu.:2.00     Class :character                 1st Qu.:0.0000
##  Median :3.00     Mode  :character                 Median :1.0000
##  Mean   :3.14                                      Mean   :0.5855
##  3rd Qu.:4.00                                      3rd Qu.:1.0000
##  Max.   :5.00                                      Max.   :1.0000
##  NA's   :3
```

```r
colSums(is.na(data))
```

```
##                                   id                                Gender
##                                    0                                     0
##                                  Age                                  City
##                                    0                                     0
##                           Profession                     Academic.Pressure
##                                    0                                     0
##                        Work.Pressure                                  CGPA
##                                    0                                     0
##                    Study.Satisfaction                      Job.Satisfaction
##                                    0                                     0
##                       Sleep.Duration                        Dietary.Habits
##                                    0                                     0
##                               Degree Have.you.ever.had.suicidal.thoughts..
##                                    0                                     0
##                      Work.Study.Hours                      Financial.Stress
##                                    0                                     3
##      Family.History.of.Mental.Illness                            Depression
##                                    0                                     0
```

Interpretacion Inicial

La variable id no representa una característica propia de los individuos, sino únicamente un identificador de cada registro. Por esta razón, no aporta información relevante para el análisis y puede excluirse sin afectar la interpretación de los resultados.

La variable Age (Edad) presenta una media y una mediana muy cercanas, lo que sugiere una distribución aproximadamente simétrica. Además, los valores se encuentran entre los 18 y los 59 años, indicando que

la muestra no está compuesta únicamente por estudiantes de pregrado, sino también por estudiantes de posgrado o personas que continúan sus estudios en etapas posteriores de la vida.

Las variables relacionadas con presión muestran resultados diferentes. Por un lado, Academic Pressure (Presión académica) se mide en una escala de 0 a 5 y tiene una media superior a 3, lo que evidencia que gran parte de los estudiantes percibe niveles relevantes de presión académica. Por otro lado, Work Pressure (Presión de trabajo) tiene una media de apenas 0.00043, es decir, prácticamente todos los registros toman el valor 0. Esto indica que la mayoría de los estudiantes no reporta presión laboral o no se encuentra trabajando, por lo que esta variable no aporta información importante para el objetivo del estudio.

De forma similar, las variables de satisfacción también presentan comportamientos contrastantes. La variable Study Satisfaction (Satisfacción con el estudio), medida en una escala de 0 a 5, tiene una media ligeramente inferior a 3. Esto representa una percepción neutral o levemente negativa hacia los estudios, lo que podría asociarse con falta de motivación, cansancio o desconexión académica. En contraste, Job Satisfaction (Satisfacción con el trabajo) tiene valores prácticamente nulos, al igual que la presión laboral, por lo que tampoco resulta útil dentro del análisis.

Respecto al desempeño académico, la variable CGPA (Rendimiento académico) presenta una media cercana a 8, lo que indica que, en general, los estudiantes tienen un buen rendimiento. Este resultado es importante porque sugiere que la presencia de depresión en la población no necesariamente está vinculada a un bajo promedio académico. Es decir, un estudiante puede tener un buen desempeño y aun así experimentar síntomas de depresión.

La variable Wor.Study.Hours (Horas de estudio/trabajo) tiene una media de 7.15 horas diarias y alcanza un máximo de 12 horas. Esto podría indicar que existe un grupo de estudiantes con una carga académica o laboral considerablemente alta, situación que puede favorecer el agotamiento, la fatiga o incluso el burnout.

Por su parte, Financial Stress (Estrés financiero) también se mide en una escala de 0 a 5 y presenta una media superior a 3, lo que indica niveles moderados o altos de preocupación económica dentro de la población. Además, esta es la única variable que contiene valores faltantes, con tres registros nulos.

Finalmente, la variable objetivo Depression (Depresión) está codificada como 0 para estudiantes sin depresión y 1 para estudiantes con depresión. Su media es de 0.5855, lo que permite interpretar que aproximadamente el 58.5 % de los estudiantes de la muestra presenta depresión. Este porcentaje es bastante alto y refuerza la importancia de analizar qué factores académicos, personales y económicos pueden estar influyendo en este fenómeno.

Variables categoricas Estas variables representan el contexto social, los habitos y los factores psicologicos

- Gender
- City
- Profession
- Sleep.Duration
- Dietary.Habits
- Degree
- Suicidal thoughts
- Family history

2. Eliminacion de duplicados

Se eliminan registros duplicados para garantizar que cada observación represente un individuo único.

```
data <- unique(data)
```

3. Correccion de tipos de datos

Se convierten variables categóricas a tipo factor para permitir su correcto análisis estadístico y visualización.

```r
# Convertir variables categóricas a factor
data$Gender <- as.factor(data$Gender)
data$City <- as.factor(data$City)
data$Profession <- as.factor(data$Profession)
data$Sleep.Duration <- as.factor(data$Sleep.Duration)
data$Dietary.Habits <- as.factor(data$Dietary.Habits)
data$Have.you.ever.had.suicidal.thoughts <- as.factor(data$Have.you.ever.had.suicidal.thoughts)
data$Family.History.of.Mental.Illness <- as.factor(data$Family.History.of.Mental.Illness)
data$Depression <- as.factor(data$Depression)
```

4. Eliminacion de la variable ID

Se elimina porque solo identifica registros, no aporta informacion para el analisis

```r
data$ID <- NULL
```

PARTE 4 - ANÁLISIS BIVARIADO

En esta sección se analizan las relaciones entre pares de variables, especialmente aquellas que potencialmente influyen en la depresión estudiantil. Se utilizan visualizaciones apropiadas según el tipo de variables involucradas.

4.1 Preparación de datos para análisis bivariado

```r
library(ggplot2)
library(dplyr)
```

```
##
## Attaching package: 'dplyr'

## The following objects are masked from 'package:stats':
##
##     filter, lag

## The following objects are masked from 'package:base':
##
##     intersect, setdiff, setequal, union
```

```r
# Crear factor de depresión para etiquetas consistentes
data$Depression_Factor <- factor(data$Depression,
                                 levels = c(0, 1),
                                 labels = c("Sin Depresión", "Con Depresión"))

# Transformar variables categóricas ordinales a numéricas para análisis
data_bivariado <- data %>%
  mutate(
    Sleep_Num = case_when(
      trimws(Sleep.Duration) == "Less than 5 hours" ~ 0,
      trimws(Sleep.Duration) == "5-6 hours" ~ 1,
      trimws(Sleep.Duration) == "7-8 hours" ~ 2,
      trimws(Sleep.Duration) == "More than 8 hours" ~ 3,
```

```r
      TRUE ~ NA_real_
    ),
    Diet_Num = case_when(
      trimws(Dietary.Habits) == "Unhealthy" ~ 0,
      trimws(Dietary.Habits) == "Moderate" ~ 1,
      trimws(Dietary.Habits) == "Healthy" ~ 2,
      TRUE ~ NA_real_
    ),
    Suicidal_Num = case_when(
      Have.you.ever.had.suicidal.thoughts == "No" ~ 0,
      Have.you.ever.had.suicidal.thoughts == "Yes" ~ 1,
      TRUE ~ NA_real_
    ),
    Family_History_Num = case_when(
      Family.History.of.Mental.Illness == "No" ~ 0,
      Family.History.of.Mental.Illness == "Yes" ~ 1,
      TRUE ~ NA_real_
    )
  ) %>%
  filter(!is.na(Sleep_Num), !is.na(Diet_Num))  # Eliminar "Others" de estas variables
```

4.2 Estrés financiero vs Depresión

Tipo de análisis: Categórica (Depresión) vs Numérica (Estrés Financiero)
Gráfico: Boxplot

```r
ggplot(data_bivariado, aes(x = Depression_Factor, y = Financial.Stress, fill = Depression_Factor)) +
  geom_boxplot(width = 0.6, alpha = 0.8) +
  scale_fill_manual(values = c("#3498db", "#e74c3c")) +
  labs(
    title = "Relación entre Estrés Financiero y Depresión",
    x = "Estado de Salud Mental",
    y = "Nivel de Estrés Financiero (1-5)"
  ) +
  theme_minimal() +
  theme(legend.position = "none")
```

```
## Warning: Removed 3 rows containing non-finite outside the scale range
## (`stat_boxplot()`).
```

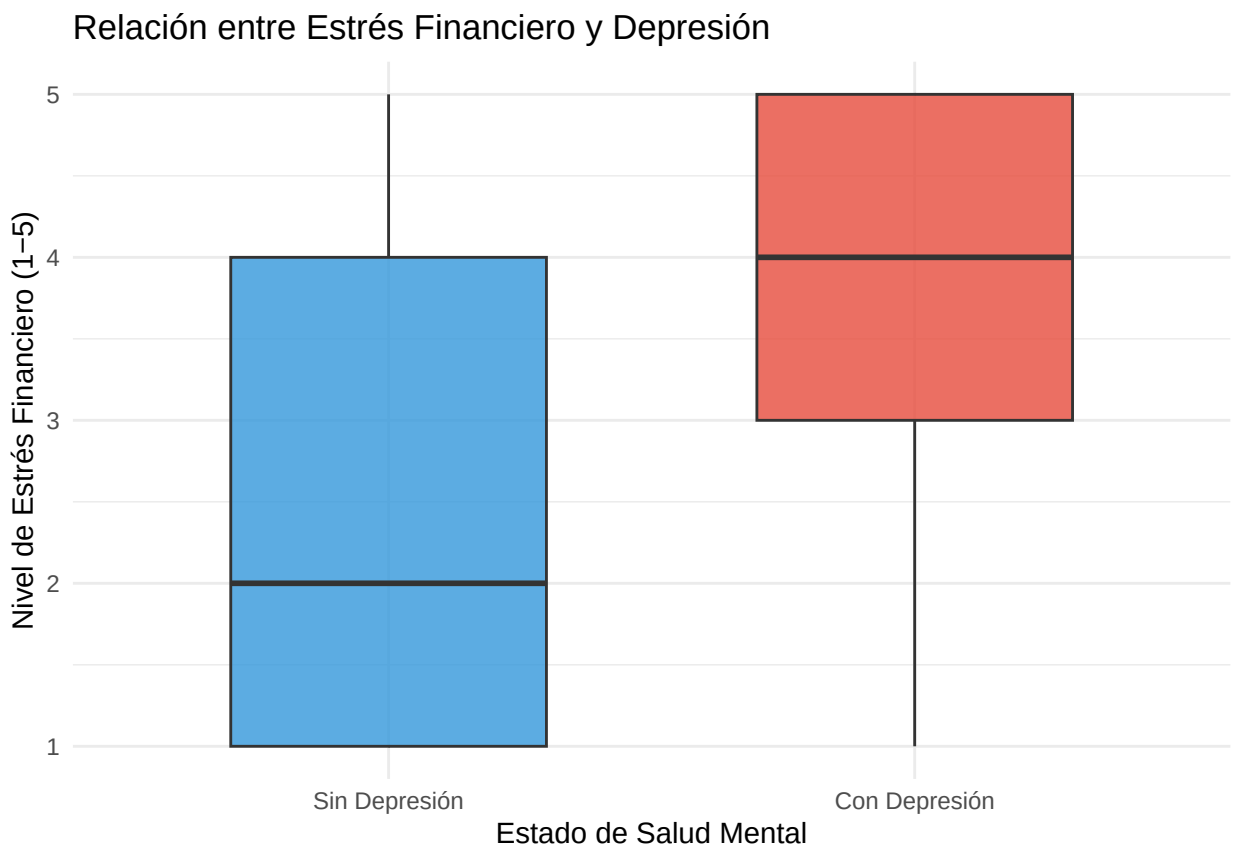

- **Interpretación**: Se puede ver qué la mediana de personas que no sufren depresión está en 2, reflejando una mayoria de estres financiero entre 2 y 4, mientras que las que tienen depresión tienen un rango entre 3 a 5 el nivel de estrés financiero , la mediana muestra que está repartida de forma uniforme el estres entre 3 - 4 y 4 - 5.

- **Conclusión**: el alto nivel de estrés financiera está más presente en la mitad de la población con depresión, lo demuestra comparando las medianas con la mayoría del grupo sin depresión que mantienen en 2-4.

4.3 Horas de estudio/trabajo vs Depresión

Tipo de análisis: Categórica (Depresión) vs Numérica (Horas) **Gráfico:** Boxplot

```
ggplot(data_bivariado, aes(x = Depression_Factor, y = Work.Study.Hours, fill = Depression_Factor)) +
  geom_boxplot(width = 0.5, outlier.shape = 16, outlier.size = 1.5,
               outlier.alpha = 0.5, color = "#2c3e50") +
  labs(
    title = "Impacto de las Horas de Estudio/Trabajo en la Salud Mental",
    x = "Estado de Salud Mental",
    y = "Horas de Estudio/Trabajo por Día"
  ) +
  scale_fill_manual(values = c("#A8DADC", "#e74c3c")) +
  theme_minimal(base_size = 12) +
  theme(
    legend.position = "none",
    plot.title = element_text(face = "bold", size = 14),
    panel.grid.minor = element_blank(),
    panel.grid.major.x = element_blank()
```

```
)
```

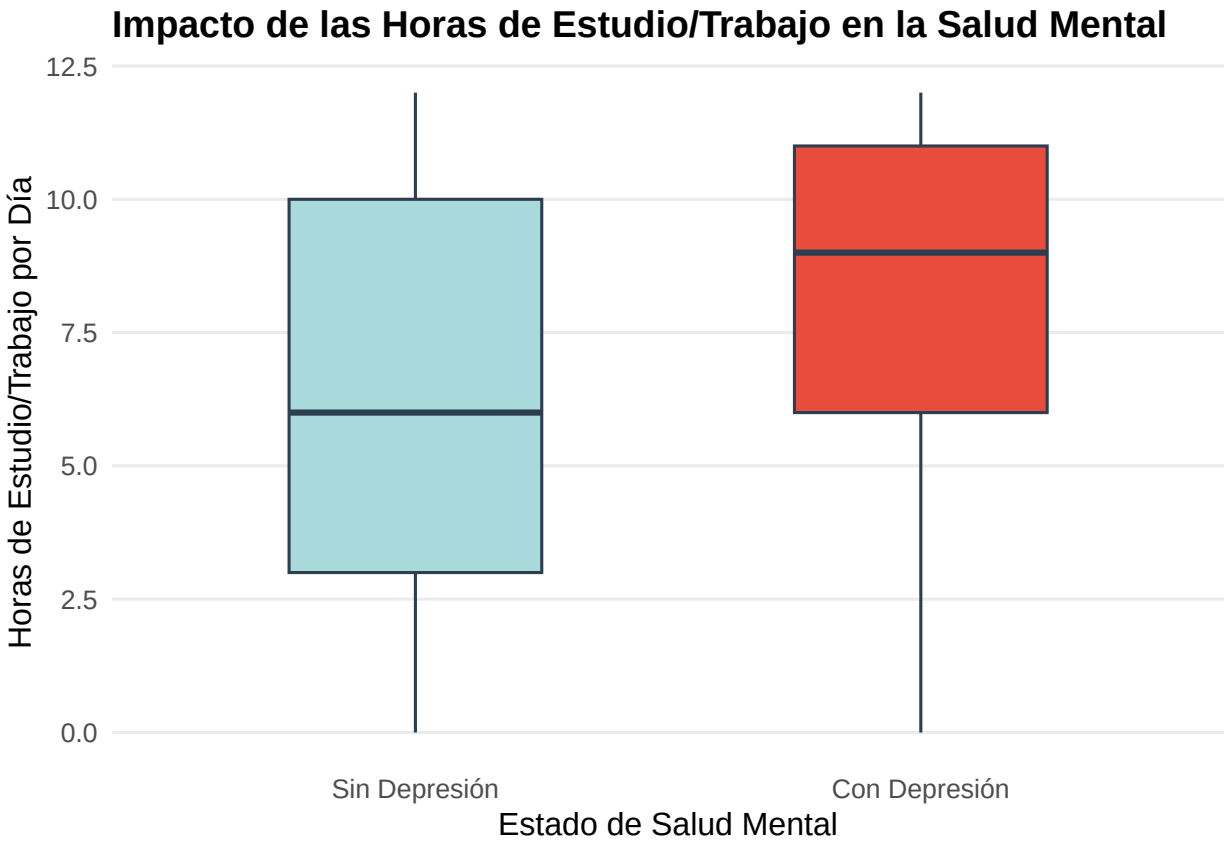

- **Interpretación**: en la gráfica boxplot se puede ver qué la mayoría de personas con depresión poseen menosrango de horas de trabajo/ estudio, con una mediana de 8 con una forma más alargada inferior, igualando el rango de las personas sin depresión, pero estás la mayoria manejan un rango más alto.
- **Conclusión**: la mayoria de personas con depresión tienen alta carga de horas de estudio y trabajo, en comparación con la mediana que no tiene depresión. estos manejan un poco menos carga laboral o de estudio.

4.4 Hábitos alimenticios vs Depresión

Tipo de análisis: Categórica ordinal vs Categórica nominal **Gráfico:** Barras agrupadas (dodge)

```r
ggplot(data_bivariado, aes(x = factor(Diet_Num), fill = Depression_Factor)) +
  geom_bar(position = "dodge", color = "black") +
  scale_x_discrete(labels = c("0" = "No saludable", "1" = "Moderado", "2" = "Saludable")) +
  scale_fill_manual(values = c("#3498db", "#e74c3c")) +
  labs(
    title = "Relación entre Hábitos Alimenticios y Depresión",
    x = "Hábito Alimenticio",
    y = "Cantidad de Estudiantes",
    fill = "Estado"
  ) +
  theme_minimal()
```

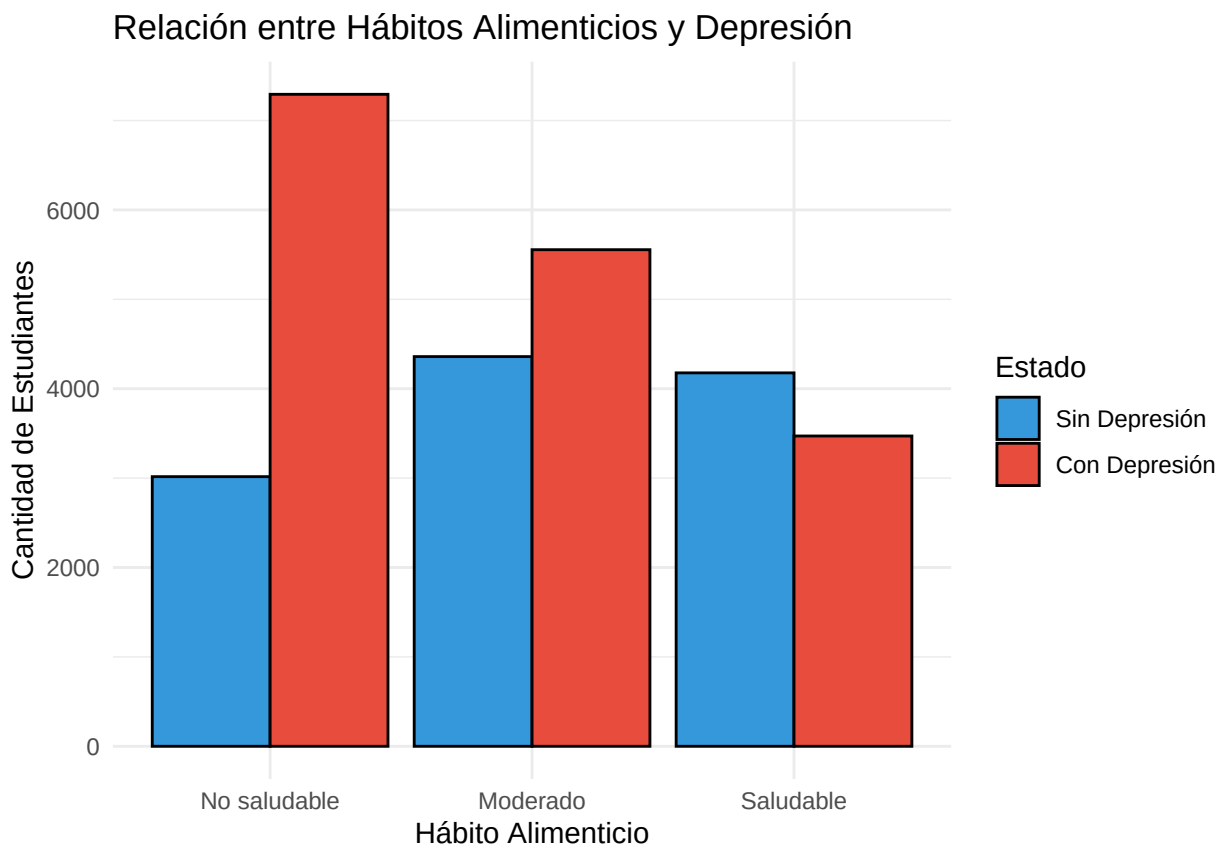

- **Interpretación**: En la gráfica de barras doble se puede ver qué en las barras de personas que tienen una dieta saludable hay más personas sin depresión, aunque la diferencia no es muy grande. En los otros 2 rangos menos saludables existe mayor presencia de gente con depresión, pero hay una mayor diferencia entre la cantidad con depresión que con la que no tiene depresión en la dieta no saludable.
- **Conclusión**: Se puede ver cómo entre menos saludable es la dieta hay una mayor presencia de personas con depresión.

4.5 Presión académica vs Depresión

Tipo de análisis: Categórica (Depresión) vs Numérica ordinal **Gráfico:** Boxplot

```
ggplot(data_bivariado, aes(x = Depression_Factor, y = Academic.Pressure, fill = Depression_Factor)) +
  geom_boxplot(width = 0.5, outlier.colour = "#e74c3c", outlier.shape = 16,
               outlier.size = 2, alpha = 0.7, color = "#2c3e50") +
  scale_fill_manual(values = c("#3498db", "#e74c3c")) +
  labs(
    title = "Distribución de la Presión Académica según Estado Mental",
    subtitle = "Comparativa de rangos intercuartílicos y medianas",
    x = "Estado de Salud Mental",
    y = "Nivel de Presión Académica (0-5)"
  ) +
  theme_minimal(base_size = 13) +
  theme(
    legend.position = "none",
    plot.title = element_text(face = "bold", color = "#2c3e50"),
    panel.grid.minor = element_blank(),
```

```
    panel.grid.major.x = element_blank()
  )
```

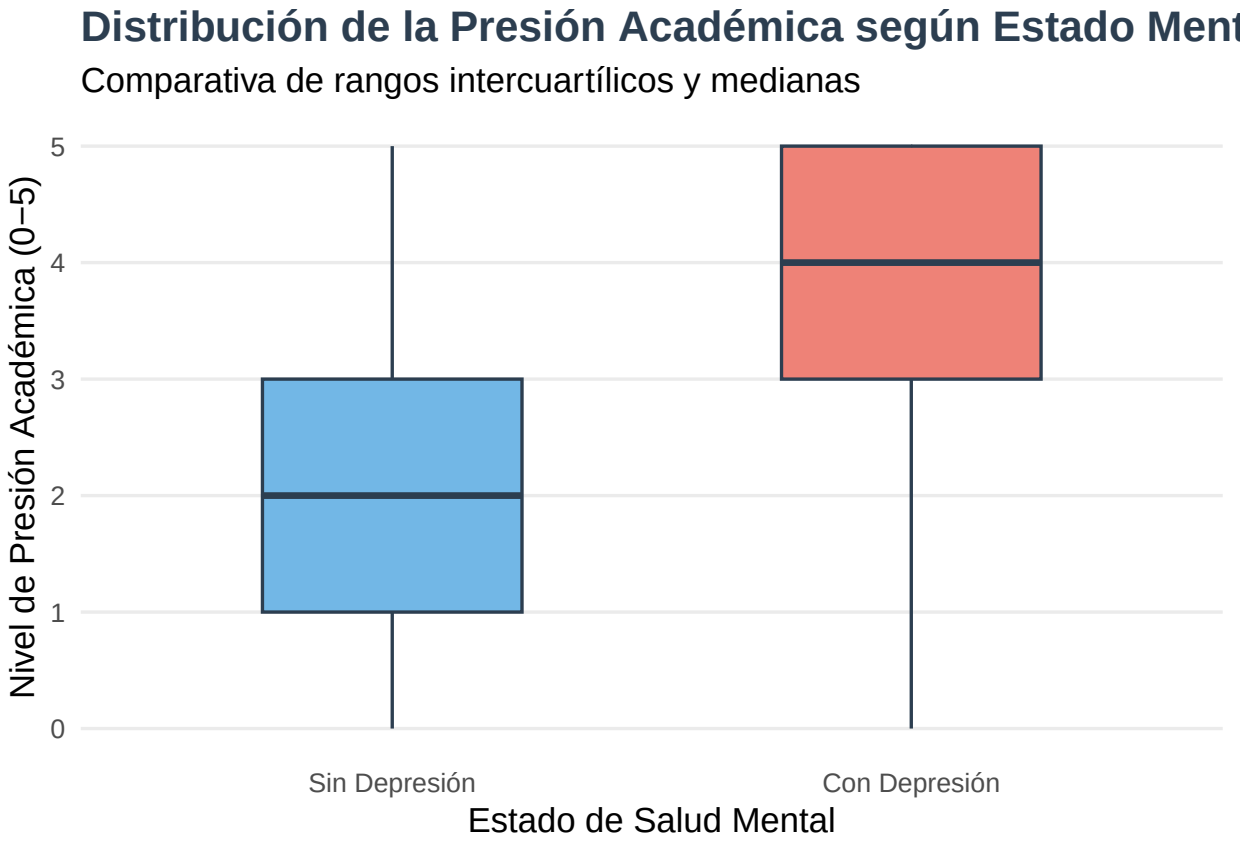

- **Interpretación**: los rangos que se manejan son casi completamente distintos,es un factor diferenciador, las medianas están separadas por dos puntos en la escala de presión academica, el rango intercuartilico es el mismo para ambos.
- **Conclusión**: el nivel de presión academico es un factor que separa a ambos grupos(los que tienen y no tienen depresión), la mediana de cada grupo está muy alejada, además de estar uniformemente en el centro, una presión academica puede ser un factor que genere depresión según el gráfico.

4.6 Duración del sueño vs Depresión

Tipo de análisis: Categórica ordinal vs Categórica nominal **Gráfico:** Barras agrupadas (dodge)

```
data_bivariado$Sleep_Grafico <- factor(data_bivariado$Sleep_Num,
                                       levels = c(0, 1, 2, 3),
                                       labels = c("Menos de 5h", "5-6h", "7-8h", "Más de 8h"))

ggplot(data_bivariado, aes(x = Sleep_Grafico, fill = Depression_Factor)) +
  geom_bar(position = "dodge") +
  scale_fill_manual(values = c("#3498db", "#e74c3c")) +
  labs(
    title = "Distribución de Depresión según Horas de Sueño",
    subtitle = "Comparativa de frecuencia por cantidad de descanso diario",
    x = "Duración del Sueño",
    y = "Cantidad de Estudiantes",
```

```
    fill = "Estado de Salud Mental"
  ) +
  theme_minimal() +
  theme(
    plot.title = element_text(face = "bold", size = 14),
    axis.title = element_text(face = "bold"),
    legend.position = "top"
  )
```

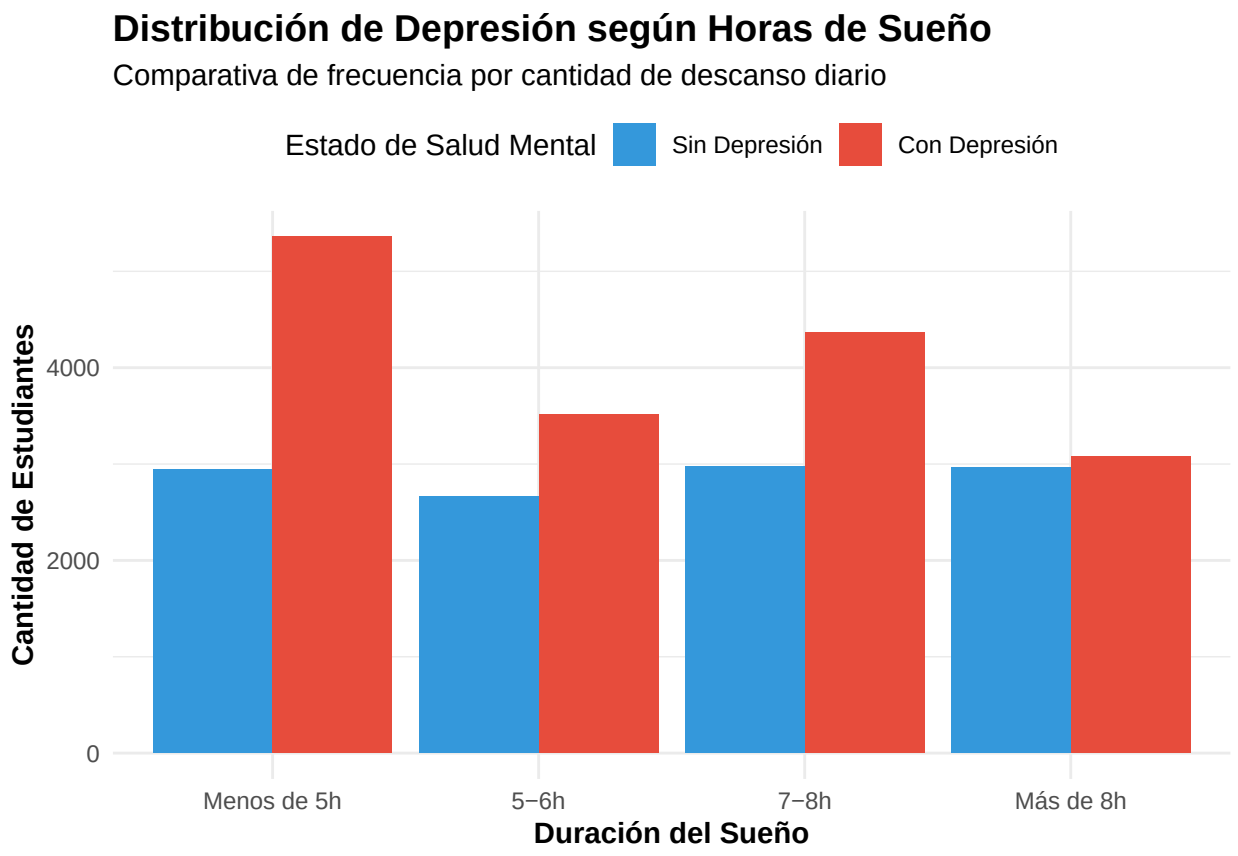

- **Interpretación**: las barras dobles muestran que no existe una gran diferencia entre el estado mental en las personas que duermen más de 8 horas pero a medida que duermen menos está diferencia se hace más grande.
- **Conclusión**: la mayoría de personas con depresión del dataset duermen menos, está diferencia contra la población que no tiene depresión es cada vez más grande entre menos tiempo duermen.

PARTE 5. Primeros hallazgos

¿Qué patrones encontraron?

El patrón más consistente del análisis inicial es la presencia de una condición de sobrecarga en el grupo con depresión. En distintas visualizaciones se repite la misma dirección: mayor presión académica, mayor estrés financiero y mayor carga horaria diaria se asocian con una mayor frecuencia de depresión.

También se observa un patrón de deterioro de hábitos en estudiantes con depresión. Dormir menos horas y presentar hábitos alimenticios menos saludables aparece de forma recurrente como una señal de riesgo, lo

que sugiere que el problema no se limita al rendimiento académico, sino que compromete la regulación del bienestar físico y emocional.

¿Qué variables dominan el comportamiento?

Las variables que más dominan el comportamiento del fenómeno son `Academic.Pressure`, `Financial.Stress`, `Work.Study.Hours` y `Have.you.ever.had.suicidal.thoughts`. En conjunto, estas variables muestran mayor capacidad para separar estudiantes con y sin depresión que otras variables del dataset.

En contraste, variables como `CGPA` muestran un comportamiento casi neutro frente al estado de depresión. Este hallazgo es clave porque indica que el desempeño académico alto no discrimina por sí solo el riesgo emocional, mientras que la carga psicológica y económica sí parece marcar diferencias claras entre grupos.

¿Qué conclusiones pueden obtener?

La primera conclusión es que la depresión en esta muestra está asociada principalmente con factores de presión acumulada y vulnerabilidad psicosocial, más que con el rendimiento académico numérico. Esto coincide con la evidencia visual y con las relaciones estadísticas observadas a lo largo del EDA.

En segundo lugar, el perfil de mayor riesgo combina alta presión, estrés financiero, poco descanso y presencia de ideación suicida. Por tanto, la depresión en estudiantes no debe abordarse como un fenómeno aislado, sino como el resultado de múltiples dimensiones que interactúan simultáneamente.

¿Qué tipo de problema podría resolverse con estos datos?

Con este dataset se puede plantear un problema de clasificación supervisada para predecir la variable `Depression` a partir de factores académicos, personales y de estilo de vida.

Adicionalmente, los datos permiten construir un sistema de estratificación de riesgo (bajo, medio, alto) útil para acompañamiento institucional. En términos aplicados, esto puede apoyar decisiones de bienestar universitario, como focalización de apoyo psicológico, programas de prevención y monitoreo de estudiantes con señales de alerta.

PARTE 6. Análisis Multivariado Básico

Matriz de Correlación

```r
library(dplyr)
data_num <- data %>%
  mutate(
    Sleep_Num = case_when(
      trimws(Sleep.Duration) == "Less than 5 hours" ~ 4,
      trimws(Sleep.Duration) == "5-6 hours" ~ 5.5,
      trimws(Sleep.Duration) == "7-8 hours" ~ 7.5,
      trimws(Sleep.Duration) == "More than 8 hours" ~ 9,
      TRUE ~ NA_real_
    ),
    Diet_Num = case_when(
      trimws(Dietary.Habits) == "Unhealthy" ~ 1,
      trimws(Dietary.Habits) == "Moderate" ~ 2,
      trimws(Dietary.Habits) == "Healthy" ~ 3,
      TRUE ~ NA_real_
    ),
    Depression_num = as.numeric(as.character(Depression)),
```

```r
    Suicidal_Num = ifelse(trimws(Have.you.ever.had.suicidal.thoughts) == "Yes", 1, 0),
    Family_History_Num = ifelse(trimws(Family.History.of.Mental.Illness) == "Yes", 1, 0)
  ) %>%

  select(Age, Academic.Pressure, CGPA, Study.Satisfaction,
         Work.Study.Hours,
         Sleep_Num, Diet_Num, Financial.Stress,
         Suicidal_Num, Family_History_Num,
         Depression_num, Depression) %>%
  na.omit()
```

```r
library(corrplot)
```

```
## corrplot 0.95 loaded
```

```r
matriz_cor <- cor(data_num %>% select(-Depression))

# Crear una paleta de colores
colores <- colorRampPalette(c("#BB4444", "#EE9988", "#FFFFFF", "#77AADD", "#4477AA"))

# Graficar ocultando la diagonal para que se vea más limpio
corrplot(matriz_cor, method = "color", type = "upper",
         col = colores(200),
         tl.col = "black", tl.srt = 45,
         addCoef.col = "black", number.cex = 0.7,
         diag = FALSE,
         title = "Matriz de Correlación", mar=c(0,0,1,0))
```

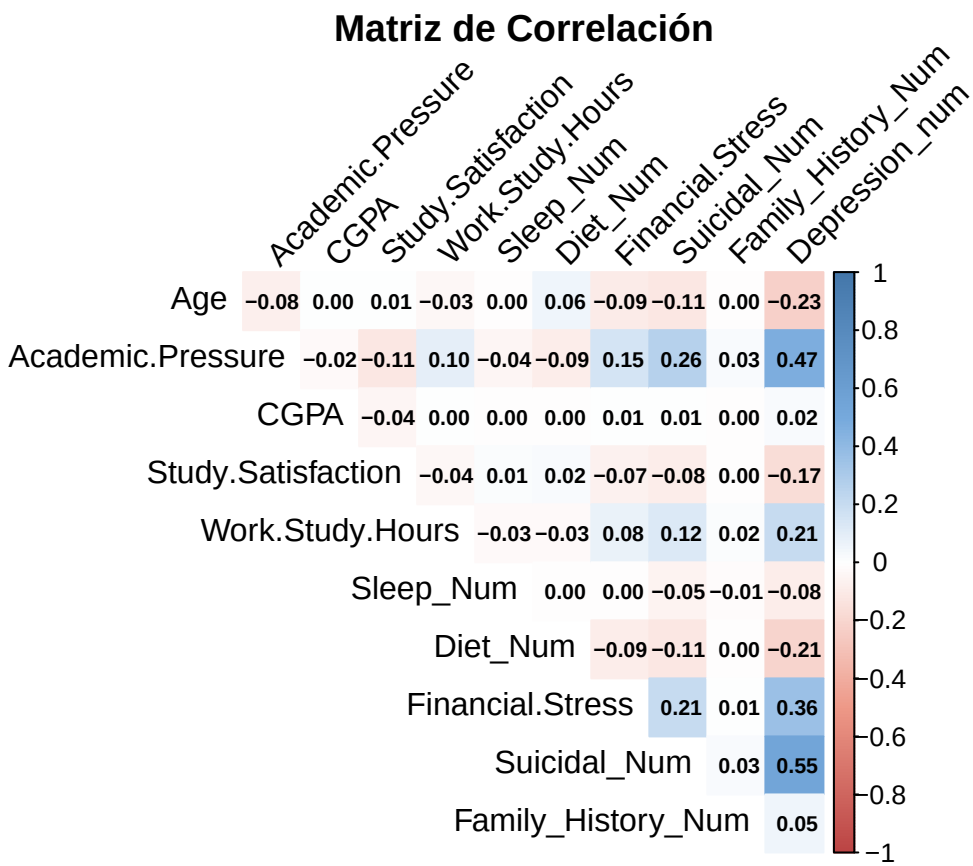

¿Qué variables están mas relacionadas?

La variable objetivo, ‘`Depression`, tiene una fuerte correlación positiva con `Academic.Pressure` (0.47) y `Financial.Stress` (0.36). Es decir, a mayor presión académica y estrés financiero, mayor probabilidad de depresión. Curiosamente, tiene una correlación negativa con `Age` (-0.23), sugiriendo que los estudiantes más jóvenes del dataset son más propensos a la depresión. Un hallazgo clave es que el `CGPA` (promedio de notas) no tiene relación alguna con la depresión (0.02). Como podría ser intuitivo, la relación más fuerte se encuentra con `Suicidal.Thoughts` (0.55), demostrando la alta relación que hay entre los pensamientos suicidas y la depresión, siendo una relación predecible a nivel intuitivo, aunque dificil de decir si los pensamientos suicidas son causa de la depresión o una consecuencia, pero lo cierto es que estan muy correlacionadas.

¿Qué patrones globales se observan?

Se observa que el estrés financiero y la presión académica se mueven en la misma dirección (tienen una correlación positiva entre sí del 0.15). El patrón global indica que la depresión estudiantil en este dataset es un problema impulsado por factores de carga mental y económica, más que por el rendimiento académico numérico (notas).

Coordenadas Paralelas

```r
library(GGally)

# 1. Creamos una columna temporal como factor para los colores
data_num$Depression_Factor <- as.factor(data_num$Depression_num)

# 2. Generamos el gráfico
ggparcoord(data = data_num,
           columns = 1:10,
           groupColumn = "Depression_Factor",
           scale = "std",
           alphaLines = 0.05) +
  scale_color_manual(values = c("0" = "#1f77b4", "1" = "#d62728")) +
  theme_minimal() +
  labs(title = "Coordenadas Paralelas (Agrupadas por Depresión)",
       x = "Variables", y = "Valor Estandarizado") +
  theme(axis.text.x = element_text(angle = 45, hjust = 1))
```

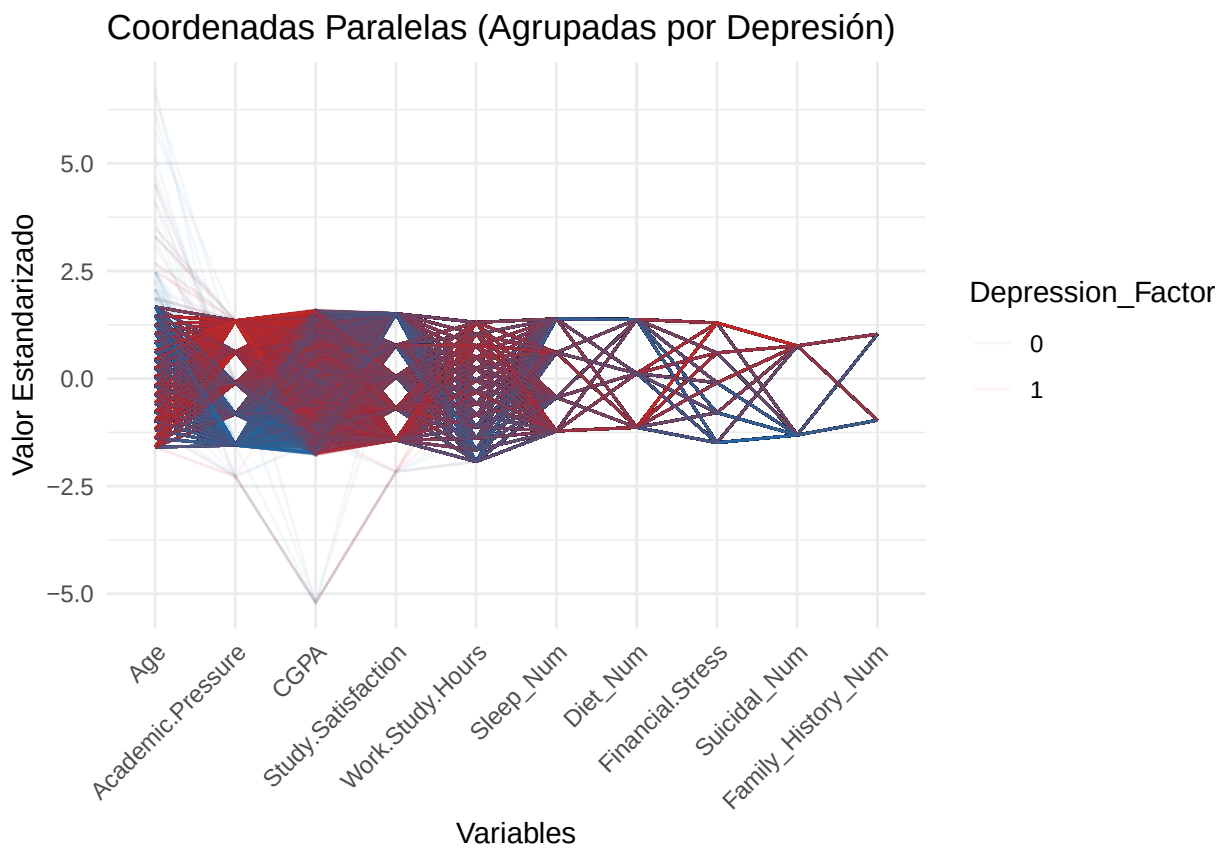


```
# 3. Borramos la columna temporal para que no afecte la Parte 7 (Medidas descriptivas)
data_num$Depression_Factor <- NULL
```

Brecha entre deprimidos y no deprimidos

Se observa una clara separación ("brecha") en los ejes de `Financial.Stress` y `Academic.Pressure`, donde la trayectoria del grupo con depresión se ubica sistemáticamente por encima del grupo sin depresión. Esto visualiza cómo estas dos cargas actúan en conjunto para perfilar a un estudiante en riesgo." En el caso de `Suicidal.Thoughts` y `Family.History` se ve la brecha más drástica y evidente de todas, en la que prácticamente todas las observaciones del grupo de deprimidos están en la parte alta y ocurre lo mismo con los no deprimidos en la parte baja, tanto así que parecen una sola linea, pero en realidad hay muchas observaciones concentradas ahí.

Puntos de cruce

El patrón global muestra una relación inversa entre el estrés y los hábitos. Mientras las líneas del grupo con depresión alcanzan picos altos en presión y estrés, caen drásticamente en los ejes de `Study.Satisfaction` y `Sleep_Num`. El perfil del estudiante con depresión es el de un sistema sobrecargado y sin recuperación (poco sueño).

Puntos de choque

Se puede evidenciar como en el eje del `CGPA` (rendimiento académico) las trayectorias de ambos grupos son casi idénticas. Gráficamente, esto demuestra que el rendimiento académico no discrimina entre un estudiante sano y uno deprimido en esta población. Esta información es acorde a lo establecido en la matriz de correlación, en la cual también se podía observar la prácticamente inexistente relación lineal entre `CGPA` y `Depression`.

¿Existen grupos de observaciones similares?

Sí. Se pueden perfilar dos grupos claros: El grupo de riesgo (alta presión, alto estrés financiero, peor dieta, historial familiar, ideaciones suicidas) y el grupo de bienestar (mayor satisfacción de estudio, menor presión, mejor alimentación, sin historial familiar, sin ideaciones suicidas).

PARTE 7. Medidas descriptivas multivariantes

Media Vectorial

```r
library(dplyr)
# Comparación de vectores de medias por grupo de depresión
tabla_centroides <- data_num %>%
  group_by(Depression_num) %>%
  summarise(across(where(is.numeric), mean)) %>%
  print(width = Inf)
```

```
## # A tibble: 2 x 11
##   Depression_num   Age Academic.Pressure  CGPA Study.Satisfaction
##            <dbl> <dbl>             <dbl> <dbl>              <dbl>
## 1              0  27.1              2.36  7.62               3.22
## 2              1  24.9              3.69  7.68               2.75
##   Work.Study.Hours Sleep_Num Diet_Num Financial.Stress Suicidal_Num
##              <dbl>     <dbl>    <dbl>            <dbl>        <dbl>
## 1             6.24      6.53     2.10             2.52        0.320
## 2             7.81      6.20     1.77             3.58        0.854
##   Family_History_Num
##                <dbl>
## 1              0.452
## 2              0.506
```

Reafirmación de hallazgos anteriores

El hallazgo más impactante se encuentra en la variable `Suicidal.Thoughts`. Mientras que en el grupo sin depresión la media es de 0.32, en el grupo con depresión se dispara a 0.85. Esto indica que el 85% de los estudiantes identificados con depresión han experimentado pensamientos suicidas. Esta diferencia de 0.53 puntos es la distancia más amplia entre ambos vectores, convirtiendo a esta variable en el principal marcador clínico del dataset.

Observamos un desplazamiento sistemático hacia valores más altos en los factores estresores para el grupo con depresión: * Presión Académica: Aumenta de 2.36 a 3.69. * Horas de Trabajo/Estudio: Sube de 6.24 a 7.81 horas diarias. * Estrés Financiero: Se eleva de 2.52 a 3.58.

El estudiante deprimido promedio vive en un estado de "sobrecarga". No solo percibe más presión, sino que objetivamente dedica más horas al día a sus responsabilidades, lo que reduce su margen de recuperación.

En el vector del grupo con depresión, las variables de bienestar muestran una caída:

Sueño (Sleep_Num): Cae de 6.53 a 6.20. Dieta (Diet_Num): Disminuye de 2.10 a 1.77.

Aunque la diferencia en horas de sueño parece pequeña, en términos poblacionales indica una tendencia a la privación crónica. Junto con una peor calidad de dieta, el centroide del grupo con depresión refleja un abandono de los hábitos biológicos básicos.

Dispersión

```r
matriz_cov <- cov(data_num %>% select(where(is.numeric)))
print("--- Matriz de Varianza-Covarianza ---")
```

```
## [1] "--- Matriz de Varianza-Covarianza ---"
```

```r
print(round(matriz_cov, 2))
```

```
##                      Age Academic.Pressure  CGPA Study.Satisfaction
## Age                24.07             -0.52  0.04               0.06
## Academic.Pressure  -0.52              1.91 -0.05              -0.21
## CGPA                0.04             -0.05  2.16              -0.09
## Study.Satisfaction  0.06             -0.21 -0.09               1.85
## Work.Study.Hours   -0.60              0.49  0.02              -0.18
## Sleep_Num          -0.04             -0.11 -0.01               0.03
## Diet_Num            0.23             -0.10  0.00               0.02
## Financial.Stress   -0.67              0.30  0.01              -0.13
## Suicidal_Num       -0.27              0.17  0.01              -0.05
## Family_History_Num -0.01              0.02  0.00               0.00
## Depression_num     -0.55              0.32  0.02              -0.11
##                    Work.Study.Hours Sleep_Num Diet_Num Financial.Stress
## Age                           -0.60     -0.04     0.23            -0.67
## Academic.Pressure              0.49     -0.11    -0.10             0.30
## CGPA                           0.02     -0.01     0.00             0.01
## Study.Satisfaction            -0.18      0.03     0.02            -0.13
## Work.Study.Hours              13.74     -0.20    -0.09             0.40
## Sleep_Num                     -0.20      3.68     0.00            -0.01
## Diet_Num                      -0.09      0.00     0.64            -0.10
## Financial.Stress               0.40     -0.01    -0.10             2.07
## Suicidal_Num                   0.22     -0.05    -0.04             0.14
## Family_History_Num             0.03     -0.01     0.00             0.01
## Depression_num                 0.38     -0.08    -0.08             0.26
##                    Suicidal_Num Family_History_Num Depression_num
## Age                       -0.27              -0.01          -0.55
## Academic.Pressure          0.17               0.02           0.32
## CGPA                       0.01               0.00           0.02
## Study.Satisfaction        -0.05               0.00          -0.11
## Work.Study.Hours           0.22               0.03           0.38
## Sleep_Num                 -0.05              -0.01          -0.08
## Diet_Num                  -0.04               0.00          -0.08
## Financial.Stress           0.14               0.01           0.26
## Suicidal_Num               0.23               0.01           0.13
## Family_History_Num         0.01               0.25           0.01
## Depression_num             0.13               0.01           0.24
```

¿Qué tan dispersos están los datos?

Se pueden encontrar covarianzas conjuntas críticas: la relación entre Work.Study.Hours y Academic.Pressure (0.49) confirma que la carga horaria no es solo fatiga física, sino que crece de la mano con la presión psicológica. Asimismo, la covarianza positiva entre Financial.Stress y Academic.Pressure (0.30) sugiere que las tensiones económicas y académicas no vienen solas; suelen presentarse como un bloque de presión acumulada que aumenta la dispersión del bienestar del estudiante.

```r
# Extraemos solo las varianzas (la diagonal de la matriz)
varianzas <- diag(matriz_cov)
```

```r
print("--- Varianzas individuales (Qué variables fluctúan más) ---")
```

```
## [1] "--- Varianzas individuales (Qué variables fluctúan más) ---"
```

```r
print(round(sort(varianzas, decreasing = TRUE), 2))
```

```
##                Age   Work.Study.Hours          Sleep_Num               CGPA
##              24.07              13.74               3.68               2.16
##   Financial.Stress  Academic.Pressure Study.Satisfaction           Diet_Num
##               2.07               1.91               1.85               0.64
## Family_History_Num     Depression_num       Suicidal_Num
##               0.25               0.24               0.23
```

¿Qué variables varían más?

Observando las varianzas individuales (la diagonal principal), `Age` (24.07) y `Work.Study.Hours` (13.75) son las que más fluctúan. Sin embargo, cabe aclarar que esto se debe a la escala de medida. La edad se mide en años y las horas de trabajo van en un rango amplio, mientras que variables como `Study.Satisfaction` o `Financial.Stress` se mueven en escalas mucho más pequeñas (ej. de 1 a 5), por lo que su varianza matemática siempre será menor (alrededor de 1.8 a 2.0).

Dependencia

```r
print("--- Dependencia (Correlación) ---")
```

```
## [1] "--- Dependencia (Correlación) ---"
```

```r
print(round(matriz_cor, 2))
```

```
##                      Age Academic.Pressure  CGPA Study.Satisfaction
## Age                 1.00             -0.08  0.00               0.01
## Academic.Pressure  -0.08              1.00 -0.02              -0.11
## CGPA                0.00             -0.02  1.00              -0.04
## Study.Satisfaction  0.01             -0.11 -0.04               1.00
## Work.Study.Hours   -0.03              0.10  0.00              -0.04
## Sleep_Num           0.00             -0.04  0.00               0.01
## Diet_Num            0.06             -0.09  0.00               0.02
## Financial.Stress   -0.09              0.15  0.01              -0.07
## Suicidal_Num       -0.11              0.26  0.01              -0.08
## Family_History_Num  0.00              0.03  0.00               0.00
## Depression_num     -0.23              0.47  0.02              -0.17
##                    Work.Study.Hours Sleep_Num Diet_Num Financial.Stress
## Age                           -0.03      0.00     0.06            -0.09
## Academic.Pressure              0.10     -0.04    -0.09             0.15
## CGPA                           0.00      0.00     0.00             0.01
## Study.Satisfaction            -0.04      0.01     0.02            -0.07
## Work.Study.Hours               1.00     -0.03    -0.03             0.08
## Sleep_Num                     -0.03      1.00     0.00             0.00
## Diet_Num                      -0.03      0.00     1.00            -0.09
## Financial.Stress               0.08      0.00    -0.09             1.00
## Suicidal_Num                   0.12     -0.05    -0.11             0.21
## Family_History_Num             0.02     -0.01     0.00             0.01
## Depression_num                 0.21     -0.08    -0.21             0.36
##                    Suicidal_Num Family_History_Num Depression_num
## Age                       -0.11               0.00          -0.23
```

```
## Academic.Pressure          0.26              0.03          0.47
## CGPA                       0.01              0.00          0.02
## Study.Satisfaction        -0.08              0.00         -0.17
## Work.Study.Hours           0.12              0.02          0.21
## Sleep_Num                 -0.05             -0.01         -0.08
## Diet_Num                  -0.11              0.00         -0.21
## Financial.Stress           0.21              0.01          0.36
## Suicidal_Num               1.00              0.03          0.55
## Family_History_Num         0.03              1.00          0.05
## Depression_num             0.55              0.05          1.00
```

¿Cómo se relacionan entre sí?

La relación más alarmante es la de Suicidal_Num con Depression_num (0.55). Esta es la correlación más alta de todo el estudio, indicando que la depresión en esta muestra está vinculada de manera casi intrínseca a un riesgo de vida.

Por otro lado, la Presión Académica (0.47) y el Estrés Financiero (0.36) emergen como los dos motores externos más fuertes de la depresión. Es notable que el CGPA (0.02) prácticamente no tiene relación con el estado depresivo, lo que rompe el mito de que el buen rendimiento protege la salud mental. Finalmente, observamos una correlación negativa importante entre los Hábitos Alimenticios (Diet_Num) y la Depresión (-0.21), lo que sugiere que el deterioro de la salud física y la falta de autocuidado son señales tempranas del colapso emocional.

PARTE 8. Interpretación global

¿Qué patrones encontraron?

El análisis exploratorio inicial sugiere que la depresión en esta muestra no aparece como un rasgo aislado de una sola dimensión, sino como parte de un perfil que se repite en distintas representaciones. Los histogramas y diagramas de caja de las varias capaz de análisis, muestran de forma reiterada desplazamientos evidentes hacia la dirección de mayor carga percibida, junto a la de menor descanso y/o hábitos menos favorables en quienes están etiquetados con depresión; las barras agrupadas refuerzan que esas diferencias no son anecdóticas, más bien se reflejan el las frecuencias de ocurrencia.

Así mismo, cuando se analiza el estudio conjunto se evidencia que la matriz de correlación resume dependencias lineales débiles pero suficientemente consecuentes entre la etiqueta de depresión y indicadores de presión, estrés económico y reportes de ideación suicida, mientras que el rendimiento académico numérico casi no se mueve con esa etiqueta en la misma escala.

Finalmente, estas comparaciones permiten observar un patrón común; aquellos estudiantes con mayores cargas, menor satisfacción o recuperación tienden a presentar más casos de depresión. Los diferentes análisis realizados coinciden en resaltar esta relación y, al integrar los resultados, refuerzan la conclusión general de que la depresión estudiantil en este conjunto de datos está asociada a mayores niveles de presión y a un menor bienestar general.

¿Qué variables dominan el comportamiento?

A escala de la muestra, la variable objetivo está desbalanceada hacia la clase positiva, lo que ya de por sí describe un fenómeno frecuente en los datos y no excepcional. En paralelo, la ocurrencia entre depresión y pensamientos suicidas es numéricamente fuerte en correlación y en las medias por grupo. Sin embargo, no es posible establecer por el momento una relación causal entre estas variables, a pesar de su fuerte conexión. Mismo caso que se aplica a la asociación negativa con la edad; en estos registros, menor edad acompaña más depresión promedio, sin extrapolar a toda la población estudiantil. Las covarianzas positivas entre presión académica, carga horaria y estrés financiero describen un bloque de tensiones que tienden a aparecer juntas y

a ampliar la dispersión del bienestar observado, siempre en el sentido estadístico de covariar, no de producirse mutuamente en sentido clínico.

¿Qué conclusiones pueden obtener?

El dataset perfila dos áreas claras en el espacio de características: una donde se agrupan más reportes de depresión junto a cargas elevadas, menos descanso y hábitos menos favorables, además de señales de riesgo psicológico y antecedentes familiares; y otra zona con el comportamiento contrario en los mismos aspectos. Que algunas dimensiones casi no diferencien a los grupos en los análisis multivariados es igual de relevante que las variables que sí marcan diferencias, ya que revela que la depresión estudiantil no puede explicarse solo por una faceta. Por eso, apoyarse únicamente en un indicador sería quedarse corto ante la variedad de datos reflejados en el análisis.

¿Qué tipo de problema podría resolverse con estos datos?

En términos prácticos, estos resultados evidencian que el dataset es adecuado para un modelo de clasificación supervisada, por lo que es apto para predecir con las variables disponibles si un estudiante tiene depresión o no. También se pueden diseñar reglas o puntajes para identificar a quienes tienen mayor riesgo y así facilitar el seguimiento. No obstante, es importante recordar que encontrar asociaciones en los datos no reemplaza el criterio de profesionales, especialmente en temas delicados como la ideación suicida, que destaca aquí como señal importante pero requiere manejo especializado.